# MyCoRe User Guide

Frank Lützenkirchen Jens Kupferschmidt Detlev Degenhardt Johannes Bühler Ulrike Krönert Ute Starke

Release 0.9.3

11. Oktober 2004

# Inhaltsverzeichnis

1. Voraussetzungen für eine MyCoRe Anwendung	8
1.1 Vorabbemerkungen	
1.2 Allgemein benötigte Software	
1.3 Hinweise zur Installation des IBM Content Manager 8.2	
1.4 Hinweise zu vorbereitenden Installationen freier Datenbanken, XML:DB's, Text-	
Suchmaschinen und Web-Komponenten	10
1.4.1 Installation der Komponenten unter Linux	10
1.4.1.1 Installation von Java	
1.4.1.2 Die Installation von MySQL	11
1.4.1.3 Die Installation der freien XML:DB eXist.	
1.4.1.4 Die Nutzung der freien Text-Suchmaschine Lucene zur Volltextsuche	12
1.4.1.5 Die Installation von Apache 2.	
1.4.1.6 Die Installation von Tomcat 5	14
1.4.2 Installation der Komponenten unter MS Windows	14
1.4.2.1 Die Installation der freien XML:DB eXist.	
2.Download und Installation des MyCoRe Kerns	15
2.1 Download des MyCoRe Kerns	
2.2 Konfiguration und Übersetzten des Kerns.	
3.Die MyCore Beispielanwendung.	18
3.1 Grundlegender Aufbau und Ziel der Beispielanwendung	18
3.1.1 Allgemeines	18
3.1.2 Datenaufbau	18
3.1.3 Die MCRObjectID	20
3.1.4 Benutzer, Gruppen und Privilegien	21
3.1.5 Das Sample-Datenmodell	22
3.1.5.1 Die Klassifikationen (Classifications)	23
3.1.5.2 Das Dokument (Document)	
3.1.5.3 Die Personendaten (LegalEntities)	24
3.2 Download der Beispielanwendung.	
3.3 Konfiguration zur Arbeit mit den Beispieldaten	
3.3.1 Grundlegende Konfigurationen	
3.3.1.1 Pfade und Systemumgebung anpassen	
3.3.1.2 JDBC-Treiber konfigurieren	26
3.3.1.3 Debug konfigurieren	
3.3.1.4 Metadaten-Store konfigurieren	
3.3.1.5 Konfiguration von IBM Content Manager 8.2	
3.3.1.6 Die Nutzung von eXist als XML:DB Backend	
3.3.1.7 Speicherung von Dokumenten konfigurieren	
3.3.1.7.1 File System Store	
3.3.1.7.2 Lucene Store.	
3.3.1.7.3 CM8 Store	
3.3.2 Laden der Beispiel-Inhalte.	
3.4 Arbeiten mit dem MyCoRe Command Line Interface.	
3.4.1 Erzeugen der Skripte mycore.sh / mycore.cmd	
3.4.2 Aufruf des CommandLineInterface.	
3.4.3 Tests auf der Basis des CommandLineInterface	
3.5 Die Zusammenarbeit mit anderen MyCoRe-Sample-Installationen.	
3.5.1 Die eigene Installation.	
3.5.2 Standard-Server des MyCoRe-Projektes	30

3.6 Erzeugen und Konfigurieren der Web-Anwendung.	
3.6.1 Erzeugen der Web-Anwendung	30
3.6.2 Konfiguration des Web Application Server	31
3.6.2.1 Tomcat	31
3.6.2.2 Websphere	31
4. Vom Sample zum eigenen Dokumenten-Server	
4.1 Allgemeines	
4.2 XML-Syntax des Datenmodells	
4.2.1 Das Klassifikationen-Datenmodell	
4.2.2 Das Metadatenmodell	
4.2.2.1 XML-Syntax eines Metadatenobjektes	
4.2.2.2 XML-Synatx des XML-Knotens structure	
4.2.2.3 XML-Syntax des XML-Knotens metadata.	
4.2.2.4 MyCoRe Metadaten-Basistypen	
4.2.2.4.1 XML-Syntax des Metadaten-Basistyps MCRMetaAddress	
4.2.2.4.2 XML-Syntax des Metadaten-Basistyps MCRMetaBoolean	
4.2.2.4.3 XML-Syntax des Metadaten-Basistyps MCRMetaClassification	
4.2.2.4.4 XML-Syntax des Metadatentyps MCRMetaCorporation.	
4.2.2.4.5 XML-Syntax des Metadaten-Basistyps MCRMetaDate	
4.2.2.4.6 XML-Syntax des Metadatentyps MCRMetaLangText	
4.2.2.4.7 XML-Syntax der Metadatentypen MCRMetaLink und MCRMetaLinkID	
4.2.2.4.8 XML-Syntax des Metadatentyps MCRMetaNumber	
4.2.2.4.9 XML-Syntax des Metadatentyps MCRMetaPerson	
4.2.2.4.10 XML-Syntax des Metadatentyps MCRMetaXML	
4.2.2.5 XML-Syntax des XML-Knotens service.	
4.2.3 Das Speichermodell für die Multimediadaten (IFS)	
4.3 Anpassungen des MyCoRe-Samples	
4.3.1 Grundlegendes.	
4.3.2 Füllen des eigenen Dokumenten-Servers	
4.4 Gestaltung der Web-Server.	
4.4.1 Nutzung von Tomcat und Apache2	
4.4.1.1 Allgemeines	
4.4.1.2 Installation von Tomcat.	
4.4.1.3 Arbeiten mit mehreren Tomcat-Instanzen.	50
4.4.1.4 Apache2 Installation	
4.4.1.5 Einrichten virtueller Hosts	
4.4.2 Arbeiten mit IBM Websphere	
4.5 Ausbau des Dokumenten-Servers mit zusätzlichen MyCoRe-Komponenten	
4.5.1 Anbindung anderer Dokumenten-Server an das System	
4.5.2 Einbindung weiterer Content Stores	
4.5.3 Nutzung der OAI Schnittstelle	
4.5.3.1 Grundlagen	59
4.5.3.2 Der OAI Data Provider	60
4.5.3.3 Installation.	
4.5.3.4 Der Deployment Descriptor	
4.5.3.5 Die mycore.properties.oai	
4.5.3.6 Instanzunabhängige Properties.	
4.5.3.7 Instanzabhängige Properties	
4.5.3.8 Test	
4.5.3.9 Zertifizierung und Registrierung	
4.6 Die Verwendung der Kommandozeilenschnittstelle der Benutzerverwaltung	

4.6.1 Allgemeine Kommandos	63
4.6.2 Kommandos zum Arbeiten mit XML-Dateien.	
4.6.3 Kommandos zum direkten Arbeiten mit Objekten der Benutzerverwaltung	
4.6.4 Das Sichern und Restaurieren der Benutzerverwaltungsdaten	65
5. Hints & Tips / Troubleshooting	66
5.1 Eine zweite Instanz von eXist auf einem System einrichten	

# Abbildungsverzeichnis

Abbildung 1: Übersicht der Objekte im MyCoRe-Sample	20
Abbildung 2: Schematisches Gruppenmodell	
Abbildung 3: XML-Syntax eines Klassifikations-Objektes	34
Abbildung 4: XML-Syntax eines Metadaten-Objektes	
Abbildung 5: XML-Syntax eines structure XML-Knotens	
Abbildung 6: XML-Syntax eines metadata XML-Knotens	
Abbildung 7: XML-Syntax des Metadaten-Basistyps MCRMetaAddress	
Abbildung 8: Beispiel des Metadaten-Basistyps MCRMetaAddress	
Abbildung 9: XML-Syntax des Metadaten-Basistyps MCRMetaBoolean	40
Abbildung 10: Beispiel des Metadaten-Basistyps MCRMetaBoolean	
Abbildung 11: XML-Syntax des Metadaten-Basistyps MCRMetaClassification	41
Abbildung 12: Beispiel des Metadaten-Basistyps MCRMetaClassification	41
Abbildung 13: XML-Syntax des Metadaten-Basistyps MCRMetaCorporation	41
Abbildung 14: Beispiel des Metadaten-Basistyps MCRMetaCorporation	42
Abbildung 15: XML-Syntax des Metadaten-Basistyps MCRMetaDate	42
Abbildung 16: Beispiel des Metadaten-Basistyps MCRMetaDate	42
Abbildung 17: XML-Syntax des Metadaten-Basistyps MCRMetaLangText	43
Abbildung 18: Beispiel des Metadaten-Basistyps MCRMetaLangText	43
Abbildung 19: XML-Syntax des Metadaten-Basistyps MCRMetaLink	44
Abbildung 20: Beispiel des Metadaten-Basistyps MCRMetaLink	
Abbildung 21: XML-Syntax des Metadaten-Basistyps MCRMetaNumber	44
Abbildung 22: Beispiel des Metadaten-Basistyps MCRMetaNumber	44
Abbildung 23: XML-Syntax des Metadaten-Basistyps MCRMetaPerson	45
Abbildung 24: Beispiel des Metadaten-Basistyps MCRMetaPerson	45
Abbildung 25: XML-Syntax des Metadaten-Basistyps MCRMetaXML	46
Abbildung 26: Beispiel des Metadaten-Basistyps MCRMetaXML	46
Abbildung 27: XML-Syntax des service XML-Konotens	47
Abbildung 28: XML-Syntax des Derivate-Datenmodells	47
Abbildung 29: Das Tomcat Konfigurationsfile server.xml	52
Abbildung 30: Das Listing des Start-Scriptes urzlib.sh	53
Abbildung 31: Die Datei workers2.properties.	56
Abbildung 32: Die Datei http.local.conf	
Abbildung 33: Ein Ausschnitt aus der Datei /etc/sysconfig/apache2	
Abbildung 34: Konfigurationseintrag für zusätzlich abzufragende Instanzen	59
Abbildung 35: Einbindung des OAI-Data-Providers in web.xml	60

# **Tabellenverzeichnis**

Tabelle 1: MyCoRe Komponentenübersicht für IBM CM	
Tabelle 2: MyCoRe Komponentenübersicht für freie Lösung.	. 9
Tabelle 3: Aufbau des MyCoRe-Kerns	
Tabelle 4: MyCoRe Document Datenmodell	
Tabelle 5: MyCoRe Document Suchschema.	
Tabelle 6: MyCoRe LegalEntity Datenmodell	
Tabelle 7: MyCoRe LegalEntity Suchschema.	
Tabelle 8: Feste Test-Instanzen für das MyCoRe-Beispiel.	
Tabelle 9: MyCoRe-Datentypen.	

#### Vorwort

Dieses Dokument ist für einen Start in das MyCoRe-System konzipiert und soll dem Einsteiger den Weg zu einer ersten MyCoRe-Anwendung, einen Dokumenten-Server, aufzeigen. Begonnen wird mit der Beschreibung alle vorab notwendigen Installationen. Weiter geht es über die Installation des MyCoRe-Kerns und des mitgelieferten Beispiels. Ein weiteres Kapitel beschreibt die Gestaltung eines ersten Dokumenten-Servers. Abschließend sind noch einige Hinweise aus der MyCoRe-Gemeinde zu Fehlerfällen notiert.

Bitte konsultieren Sie bei Detailfragen auch das mitgelieferte Programmer Guide, hier sind die Einzelheiten von MyCoRe genau dokumentiert.

ACHTUNG, diese Dokumentation basiert auf dem Release 0.9 der MyCoRe-Software!

# 1. Voraussetzungen für eine MyCoRe Anwendung

## 1.1 Vorabbemerkungen

Das MyCoRe-Projekt ist so designed, dass es dem einzelnen Anwender frei steht, welche Komponenten er für die Speicherung der Daten verwenden will. Dabei spielt natürlich das verwendete Betriebssystem eine wesentliche Rolle. Jedes System hat seine eigenen Vor- und Nachteile, die an dieser Stelle nur kurz diskutiert werden sollen. Wir wollen es dem Anwender überlassen, in welchem System er für seine Anwendung die größten Vorteile sieht. Nachfolgend finden Sie eine Tabelle der wesentlichen eingesetzten Komponenten entsprechend des gewählten Basissystems.

Allg. Basis	komerzieller IBM Content Manager	
<b>Metadaten Store</b>	IBM Content Manager 8.2 mit integrierter Text-Suchmaschiene IBM NSE	
Volltextsuche	Diese ist für die Nutzung des IBM CM Ressource Managers voll integriert.	
Datenbank	Es wird die mitgelieferte DB2 Datenbank benutzt.	
<b>Dokument Stores</b>	Filesystem	
	IBM CM Ressource Manager IBM Video Carger Helix Server	
Web-Server	IBM WebSphere	
Servlet-Engine	IBM WebSphere	
OS	IBM AIX Sun Solaris Linux Microsoft Windows	
Vorteile	- Parametrische Metadaten-Werte können ggf. auch volltextindiziert und s gesucht werden werden.	
	<ul> <li>Gute Implementierung der an XPath angelehnten Abfragesprache</li> <li>Viele Dokumenttypen lassen sich automatisch volltextindizieren.</li> <li>Das Basisprodukt kommt von einem Hersteller.</li> </ul>	
	- Viel unterstützte Dateiformate für die Volltextsuche	
Nachteile	<ul> <li>Sehr komplexe Installation des benötigten Content Manager /WebSphere Systems.</li> <li>Abhängigkeit von den IBM Lizenz-Bedingungen.</li> </ul>	

Tabelle 1: MyCoRe Komponentenübersicht für IBM CM

Allg. Basis	Lösung auf freien Komponenten	
<b>Metadaten Store</b>	Es wird die freie XML:DB eXist benutzt.	
Volltextsuche in Datenbank	Es wird die freie Text-Suchmaschine Lucene benutzt. Es wird die freie Datenbank MySQL benutzt.	
<b>Dokument Stores</b>	Filesystem	
	Lucene für Textdokumente IBM Video Carger Helix Server	
Web-Server	Apache / Tomcat	
Servlet-Engine	Tomcat	
OS	Linux Microsoft Windows	
	alle weiteren UNIX-Systeme, sofern die benötigten Komponenten vorhanden sind	
Vorteile	- Geringe Kosten durch die Nutzung freier Komponeneten.	
	- Keine direkte Bindung an einen Hersteller.	
	- Die Komponenten sind fast plattformunabhängig, einfach zu installieren gut getestet und dokumentiert.	
	- Es kann schnell eine Anwendung fertiggestellt werden.	
Nachteile	- Abhängikeit von der Entwicklung in der OpenSource-Gemeinde.	
- Keine Produkthaftung für Komponenten.		
	- Derzeit werden nur PDF und TXT für die Volltextsuche unterstützt.	
	- XPath-Abfragen sind nicht in wenigen Teilen bei eXist fehlerhaft bzw. geben fasche Angaben zurück.	

Tabelle 2: MyCoRe Komponentenübersicht für freie Lösung

## 1.2 Allgemein benötigte Software

Zum Betrieb von MyCoRe sind zuerst einmal die folgenden freien Komponenten nötig:

- Java SDK es ist mindestens ein SDK 1.3.1 erforderlich. Java wird normalerweise mit dem Betriebssystem ausgeliefert. Eine Installation ist in den entsprechenden Abschnitten beschrieben.
- BASH (erforderlich unter Unix-Systemen) Alle zusätzlichen Unix-Shell-Scripts basieren auf der bash-Shell. Es ist also sehr sinnvoll, diese auf dem System mit zu installieren, sofern sie noch nicht vorhanden ist.
- CVS-Client (erforderlich) Dieser dient dem Checkout des aktuellen MyCoRe-Codes und ist für den Einbau von Bug-Fixes unerlässlich. CVS ist in der SuSE-Linux-Distribution enthalten. Für andere Systeme muss es von einem separaten Server¹ nachgeladen werden.
- ANT (erforderlich) Unter Linux ist dieses Tool in den Distributionen enthalten, für die anderen

<sup>1 &</sup>lt;a href="http://cvshome.org/">http://cvshome.org/</a>

Systeme muss es vom Server des Apache-Projektes<sup>2</sup> geholt werden. Es sollte mindestens Version 1.5.x zum Einsatz kommen.

• ImageMagick (optional) – Ein mächtiges Bildkonverter-Programm, welches bei der Bearbeitung großer Bildmengen sehr hilfreich ist. Auch dieses Produkt ist in Linux-Distributionen mit enthalten.

Für das Betriebssystem AIX stellt die Firma IBM einen Software-Download unter <a href="http://ftp.software.ibm.com/">http://ftp.software.ibm.com/</a> bereit.

## 1.3 Hinweise zur Installation des IBM Content Manager 8.2

Die Installationshinweise für den IBM Content Manager sind recht umfangreich. Wir haben uns daher entschieden, diese in einem gesonderten Dokument abzulegen. Es enthält sowohl die Hinweise für die Installation der Komponenten unter AIX wie auch unter Windows und Linux. Die Schrift gehört zur Reihe der MyCoRe Quick Guides und heißt 'Installing IBM CM 8.2'. Bitte konsultieren Sie erst diese Schrift, bevor sie mit der Installation vom MyCoRe und der Beispielanwendung auf IBM Content Manager Basis fortfahren. Die in der nachfolgenden Beschreibung angegebenen Arbeiten gehen davon aus, dass der Nutzer für des MyCoRe-Kerns und des Beispiels mit mcradmin angegeben ist.

# 1.4 Hinweise zu vorbereitenden Installationen freier Datenbanken, XML:DB's, Text-Suchmaschinen und Web-Komponenten

## 1.4.1 Installation der Komponenten unter Linux

Die folgende Beschreibung erläutert die vorbereitenden Arbeiten unter SuSE Linux. Getestet wurde unter der Version 9.1. Es ist besonders aus Sicherheitsgründen besonders zu empfehlen, auch die vom Distributor angebotenen Updates für die nachfolgenden Komponenten nachzuinstallieren. Sollten für RedHat Abweichungen auftreten, so werden diese gesondert vermerkt.

#### 1.4.1.1 Installation von Java

Als erster Schritt ist der Java-Compiler J2SE 1.4.1 oder höher zu installieren. JRE und SDK befinden sich unter in der SuSE in der Distribution. Zum Test unter 9.0 wurden Java 1.4.2 verwendet. Probleme mit höheren Versionen sind bisher nicht bekannt.

- java2-jre-1.4.2-35
- · java2-1.4.2-35

Wenn allerdings SuSE von einem ftp Server installiert wird, so ist Java nicht standardmäßig enthalten. In diesem Fall gehen Sie bitte wie folgend vor:

- 1. Holen sie bitte die Java Linux Version von der <a href="http://www.blackdown.org">http://www.blackdown.org</a> Homepage.
- 2. Installieren Sie den Download kann beispielsweise nach /usr/local.
- 3. chmod +x j2sdk-1.4.2-<VERSION>-linux-<ARCH>-<GCC>.bin
- 4../j2sdk-1.4.2-<VERSION>-linux-<ARCH>-<GCC>.bin
- 5. Damit die Pfad Variablen alle richtig gesetzt werden eine Vorlage unter /etc/java entsprechend editieren und mit setDefaultJava als root die Links richtig setzten.

<sup>2 &</sup>lt;a href="http://ant.apache.org/">http://ant.apache.org/</a>

<sup>3 &</sup>lt;u>ftp://ftp.informatik.hu-berlin.de/pub/Java/Linux/</u>

- 6. Nun prüfen sie bitte bei Verwendung von JDK 1.4.x noch, mit welcher XALAN-Version sie arbeiten. Diese muss gleich der von MyCoRe mitgelieferten Version sein, damit Inkonstitenzen vermieden werden! Ist dies nicht der Fall, beachten Sie bitte die Hinweise unter Punkt 2.2. Der Test geschieht mit java org.apache.xalan.xslt.EnvironmentCheck
- 7. Zudem sollte man in der Datei /etc/profile.local<sup>4</sup> noch die Variable ANT\_HOME<sup>5</sup> gesetzt werden

Die weiteren Beschreibungen gehen davon aus, dass die Applikation unter dem Nutzer **mcradmin** läuft. Richten sie diesen ggf. noch ein.

## 1.4.1.2 Die Installation von MySQL

MySQL ist eine derzeit freie relationale Datenbank, welche zur schnellen Speicherung von Daten innerhalb des MyCoRe-Projektes benötigt wird. Sie besitzt eine JDBC Schnittstelle und ist SQL konform. Sie könnten MySQL auch durch eine andere verfügbare Datenbank mit gleicher Funktionalität ersetzen. Der Test erfolgte mit einem MySQL 4.x System, höhere Versionen sollten keine Probleme bereiten.

- 1. Installieren Sie aus Ihrer Distribution die folgenden Pakete und danach ggf. noch vom Hersteller der Distribution per Netz angebotene Updates. Die angegebenen Versionsnummern sind nur exemplarisch.
  - mysql-4.0.18-...
  - mysql-shared-4.0.18-...
  - mysql-client-4.0.18-...
  - mysqlcc-0.9.4-84
- 2. Die Dokumentation steht nun unter /usr/share/doc/packages/mysql.
- 3. Führen Sie als **root** das Kommando rcmysgl start aus.
- 4. Führen Sie als **root** das Kommando aus

```
/usr/bin/mysqladmin -u root password new-password
/usr/bin/mysqladmin -u root -h <full_host_name> password new-
password
```

5. Die folgende Sequenz sorgt dafür, dass der MyCoRe-User **mcradmin** alle Rechte auf der Datenbank hat. Dabei werden bei der Ausführung von Kommandos von **localhost** aus keine Passwörter abgefragt. Von anderen Hosts aus muss *ein-password* eingegeben werden.

```
mysql -uroot -pPASSWORD mysql
GRANT ALL PRIVILEGES ON *.* TO mcradmin@localhost WITH GRANT
OPTION;
GRANT ALL PRIVILEGES ON *.* TO mcradmin@'%' IDENTIFIED BY 'ein-
passwort' WITH GRANT OPTION;
quit
```

- 6. Ist das Password einmal gesetzt, müssen Sie zusätzlich die Option -p verwenden.
- 7. Zum Verifizieren, ob der Server läuft, nutzen Sie folgende Kommandos mysqladmin -u mcradmin version mysqladmin -u mcradmin variables.
- 8. Jetzt können Sie die Datenbasis für MyCoRe mit nachstehendem Kommando anlegen. mysqladmin -u mcradmin create mycore
- 9. Falls weitere Benutzer noch das Recht auf Selects von allen Hosts aus haben sollen, verwenden Sie die Kommandos

<sup>4</sup> Falls diese noch nicht existiert einfach anlegen.

<sup>5</sup> export ANT HOME=/usr/share/ant

```
mysql -u mcradmin mycore
GRANT SELECT ON mycore.* TO mcradmin@'%';
quit
```

Falls sie keine Connection auf ihren Rechnernamen (nicht localhost) aufbauen können, kann es auch mit ihrer Firewall oder TCPWrapper Einstellung zu tun haben. Bei einer Firewall sollte der Port 3306 freigegeben werden und bei einem TCPWrapper der entsprechende Dienst (**mysqld**) in die Datei /etc/hosts.allow geschrieben werden.

#### 1.4.1.3 Die Installation der freien XML:DB eXist

eXist ist eine frei verfügbare XML:DB, welche die entsprechenden Interfaces implementiert. Für MyCoRe wurde ein auf diesen Schnittstellen basierender Persitence-Layer implementiert. So ist die Nutzung von eXist direkt möglich.

#### Vorbedingungen

Für das folgende Szenario ist darauf zu achten, dass der Tomcat bzw. Websphere Server nicht auf den Port 8080 hört, da es ansonsten zu einem Konflikt mit der hier vorgestellten Installation kommt, weil der eXist servlet Container ebenfalls standardmäßig auf den port 8080 hört. Den Port für Tomact ändern sie in der tomcatinstalldir/conf/server.xml.

#### Installation

- 1. Download der aktuellen Version von eXist<sup>6</sup>. Achtung, da dieses Produkt noch stark im Wachsen ist, sollte hier ggf. die letzte Version geholt werden (CVS). Zum Test kam Version eXist-1.0b1.
- 2. Entpacken Sie die Distribution in ein entsprechendes Verzeichnis, z. B. unter /home/mcradmin (eXist-installdir).
- 3. Entfernen Sie zur Nutzung des Stand-Alone-Servers den Kommentar aus der Zeile uri=xmldb:exist://localhost:8081 im File *client.properties*
- 4. Kommentieren Sie folgende Zeile aus.

```
uri=xmldb:exist://localhost:8080/exist/xmlrpc
```

Dies Einstellung wird zum Beispiel für die direkte Einbindung in Tomcat verwendet, wenn man über xmlrpc auf eXist zugreifen möchte.

- 5. Unter Linux müssen noch die Shell-Scripts ausführbar gemacht werden.
  - chmod 755 <eXist-installdir>/bin/\*.sh
- 6. Starten Sie den Server mit <eXist-installdir>/bin/startup.sh
- 7. unter der URL http://localhost:8080/exist/index.xml sollte jetzt die eXist-Homepage erscheinen. Dies nur als Test.
- 8. Wenn alles okay ist, starten Sie <eXist-installdir>/bin/server.sh
- 9. Anschliessend können Sie auch den Client mit <eXist-installdir>/bin/client.sh starten. Hier sollten Sie dem Admin-User ein Password spendieren.

### 1.4.1.4 Die Nutzung der freien Text-Suchmaschine Lucene zur Volltextsuche

Um die frei verfügbare Text-Suchmaschine für die Volltextsuche Lucene des Apache Jakarta Projektes<sup>7</sup> zu benutzen, bedarf es keiner zusätzlichen Installationen. Derzeit ist die Version Lucene 1.3 Final Released aktuell. Die erforderliche *lucene-1.3-final.jar* Datei wird unter dem MyCoRe-

<sup>6 &</sup>lt;a href="http://exist-db.org">http://exist-db.org</a>

<sup>7</sup>http://jakarta.apache.org/lucene/docs/index.html

Kern im Verzeichnis ~mycore/lib mitgeliefert. Zur Nutzung ist lediglich die weiter hinten beschriebene Konfiguration in der MyCoRe-Anwendung nötig.

Im derzeitigen Entwicklungsstand können mit der MyCoRe Variante auf Basis freier Software nur folgende Dateitypen textindiziert werden. Hierzu müssen noch folgende Tools installiert werden. Diese sollten in den gängigen Linux-Distributionen enthalten sein. Installieren Sie also

Indizieren von PDF-Dateien (\*.pdf)

· xpdf-3.00-...

Achtung, es können selbstverständlich nur PDF-Dateien indiziert werden, welche auch reinen Text und nicht den Text als Bild enthalten!

Indizieren von OpenOffice-Dateien (\*.sxw)

• OpenOffice org-1.1.1-...

Achtung, Sie müssen nach der Installation von OpenOffice dieses unter **mcradmin** initialisieren indem Sie das Produkt einmal aufrufen.

Indizieren von PostScript-Dateien (\*.ps)

ghostscript-...-7.07.1rc1...

Die Praxis hat gezeigt, dass einige PostScript Ausprägungen nicht gelesen werden können (Fehler beim Öffnen)!

#### 1.4.1.5 Die Installation von Apache 2

Im Linux-Umfeld kann der Apache-Webserver als Standard betrachtet werden. Er ist in allen gängigen Distributionen enthalten. Die allerneuesten Apache 2 Pakete sind zu finden unter <a href="ftp://ftp.suse.com/pub/projects/apache/apache2/9.0-i386">ftp://ftp.suse.com/pub/projects/apache/apache2/9.0-i386</a> Der Test erfolgte unter SuSE 9.1 mit folgenden Versionen:

- apache2-2.0.49-...
- apache2-doc-2.0.49-... (dieses Paket ist optional)

Mit rcapache2 start wird der Server per Default Einstellungen gestartet und sollte jetzt über http://localhost erreichbar sein. Etwaige Fehlermeldunge werden in die Fehler-Datei / var/log/apache2/error log geschrieben.

Die zentrale Konfigurationsdatei des Apache2 ist die unter /etc/apache2 liegende Datei httpd.conf. Bevor irgendwelche Änderungen vorgenommen werden bitte immer ein Sicherheitskopie anlegen. Der Befehl (als root) /usr/sbin/apache2ctl configtest überprüft die Syntax ihrer geänderten Einstellungen. Vorerst sollten jedoch die Standard Einstellungen genügen. Mit rcapache2 [start; stop; restart] als root kann der Server gestartet gestoppt bzw. neu gestartet werden und über rcapache2 status wird der aktuelle Staus abgefragt. Die Einbindung von virtuellen Web-Serveren und von Tomcat wird weiter hinten besprochen.

#### 1.4.1.6 Die Installation von Tomcat 5

Wie Apache, dessen Installation im vorigen Abschnitt beschrieben wurde, ist auch Tomcat als Servlet-Engine im Linux-Umfeld ein Quasi-Standard. Für die Arbeit der Web-Anwendung des MyCoRe-Projektes wird dieses Tool zwingend benötigt. Getestet wurde unter SuSE 9.1 mit folgenden Komponenten:

- jakarta-tomcat-5.0.19-32
- apache2-jakarta-tomcat-connectors-5.0.19-32

Im File /etc/profile.local ist folgender Eintrag vorzunehmen, damit Tomcat auch von mcradmin genutzt werden kann. Weiterhin werden der Memory Size für den Server erweitert.

- export CATALINA HOME=/opt/jakarta/tomcat
- export CATALINA\_OPTS="\$CATALINA\_OPTS -server -Xms256m -Xmx1800m -Xincgc"

Mit rctomcat [start; stop; restart] als root kann der Server gestartet gestoppt bzw. neu gestartet werden und über rctomcat status wird der aktuelle Staus abgefragt. Nach Standardadresse starten Tomcat Servers sollte er unter der des http://localhost:8080/examples erreichbar sein. Bitte beachten Sie aber, dass der standardmäßige Port 8080 auch von eXist (falls Sie dies verwenden) verwendet wird. In diesem Fall müssen Sie in der Konfigurationsdatei server.xml einen anderen Port auswählen. Die Dokumentation steht unter http://localhost:8080/tomcat-docs. Die Einbindung von Tomcat in virtuelle Hosts ist weiter unten beschrieben.

## 1.4.2 Installation der Komponenten unter MS Windows

#### 1.4.2.1 Die Installation der freien XML:DB eXist

eXist ist eine frei verfügbare XML:DB, welche die entsprechenden Interfaces implementiert. Für MyCoRe wurde ein auf diesen Schnittstellen basierender Persistence-Layer implementiert. So sollte die Nutzung von eXist direkt möglich sein.

- 1. Download der aktuellen Version von eXist<sup>8</sup>. Achtung, da dieses Produkt noch stark im Wachsen ist, sollte hier die letzte Version geholt werden. Zum Test kam Version eXist-1.0.
- 2. entpacken Sie die Distribution in ein entsprechendes Verzeichnis.
- 3. Entfernen Sie zur Nutzung des stand-alone-Servers den Kommentar aus der Zeile uri=xmldb:exist://localhost:8081 in <installdir>\eXist-1.0\client.properties
- 4. Starten Sie <installdir>\eXist-1.0\bin\server.bat
- 5. Anschließend können Sie auch den Client mit <installdir>\eXist-1.0\bin\client.bat starten. Hier sollten Sie dem Admin-User ein Password spendieren.

<sup>8 &</sup>lt;a href="http://exist-db.org/">http://exist-db.org/</a>

# 2.Download und Installation des MyCoRe Kerns

## 2.1 Download des MyCoRe Kerns

Derzeit steht der MyCoRe-Kern unter server<u>mycore.de</u>. Sie müssen also zuerst ein kleines Shell-Script cvsmycore.sh erstellen, welches die erforderlichen Variablen setzt.

```
#Script zum Zugriff auf das CVS in Essen
export CVS_CLIENT_LOG=~/cvs_log
export TERM=vt100
export CVS_ROOT=:pserver:anoncvs@server.mycore.de:/cvs
export CVS_RSH=ssh
cvs $*
```

Führen Sie zuerst folgendes Kommando aus (das Passwort ist anoncvs)

```
touch ~/.cvspass ; cvsmycore.sh login
```

Der MyCoRe Kern wird für alle unterstützten Systeme über das CVS Repository ausgeliefert. Das Holen der aktuellen Version erfolgt mit dem Kommando

```
cvs -d :pserver:anoncvs@server.mycore.de:/cvs checkout mycore
```

Nach dem erfolgreichen CheckOut erhalten Sie unter dem Verzeichnis ~/mycore folgende Dateistruktur. Es ist erforderlich, diese Pfadangabe in der Umgebungsvariablen MYCORE\_HOME abzulegen.

Relativer Pfad	Inhalt	
bin	Das Verzeichnis für die Shell-Scripts des Kerns.	
bin/build.cmd	Startet den Build-Prozess unter einem Windows-System.	
bin/build.sh	Startet den Build-Prozess unter einem Unix-System.	
bin/build.properties	Konfigurationsdatei für den Kern, welche die Pfade zu den verwendeten Datenspeichern enthält.	
build.xml	Die Konfigurationsdatei für den Build-Prozess.	
documentation	Enthält alle MyCoRe-Dokumentationen.	
documentation/StartingGuide	Eine kurze Einleitung in das Projekt.	
documentation/UserGuide	Das Handbuch für die Standard-Installation von MyCoRe.	
Documentation/QuickGuide	Einige Kurzbeschreibungen zu ganz bestimmten Spezialthemen rund um MyCoRe.	
lib	Java-Archive von Komponenten, welche in MyCoRe genutzt werden.	
license.txt	Die verbindliche Lizenz von MyCoRe.	
schema	XML Schema Dateien des MyCoRe-Kerns.	
sources/sources/org	Verzeichnis des Java-Quellcodes. Eine Beschreibung der Pakete steht im ProgrammerGuide.	
stylesheets	XSLT Stylesheets des MyCoRe-Kerns.	

Tabelle 3: Aufbau des MyCoRe-Kerns

# 2.2 Konfiguration und Übersetzten des Kerns

- 1. MyCoRe verwendet das Apache Ant Build-Tool, um den Quellcode zu übersetzen und eine vollständige Beispiel-Applikation zu erzeugen. Entsprechend der Installationsanleitung des Ant-Paketes sollten Sie zunächst die Umgebungsvariable JAVA\_HOME und ANT\_HOME gesetzt haben. Sollten diese Variablen auf Ihrem System noch nicht gesetzt sein, können Sie dies in der Datei build.sh (Unix) bzw. build.cmd (Windows) nachholen und korrigieren.
- 2. Es ist nicht nötig, weitere Umgebungsvariablen wie etwa den Java CLASSPATH zu setzen. Das MyCoRe Ant Build-Skript ignoriert den lokal gesetzten CLASSPATH völlig und generiert stattdessen einen eigenen CLASSPATH entsprechend Ihrer Konfiguration. Somit können wir sicherstellen, dass nur die erforderlichen Pakete und Klassen in der richtigen Version verwendet werden. Die Konfiguration der Systemumgebung der verwendeten Datenbanken für die XML-Speicherung (IBM CM8, Apache Xindice, eXist) und die Speicherung von Tabellen über JDBC in einer relationalen Datenbank (IBM DB2, MySQL, optional auch andere) wird in der Datei bin/build.properties festgelegt.
- 3. In der Regel werden Sie nur die beiden entsprechenden Blöcke für die verwendete XML-Datenbank (MCR.XMLStore.\*) und die verwendete relationale Datenbank (MCR.JDBCStore.\*) durch kommentieren bzw. auskommentieren der vorgegebenen Zeilen MCR.XMLStore.BaseDir Anpassen der beiden Variablen MCR. JDBCStore. BaseDir an die lokalen Installationsverzeichnisse Ihrer Datenbanksysteme anpassen müssen. Die weiteren Variablen steuern die für den Betrieb notwendigen JAR-Dateien (MCR.\*Store.Jars), eventuell zusätzlich in den CLASSPATH einzubindende class-Dateien oder Ressourcen (MCR.\*Store.ClassesDirs) und zur Laufzeit erforderliche native Libraries bzw. DLLs (MCR.\*Store.LibPath). Passen Sie die Werte entsprechend der Dokumentation Ihres Datenbankproduktes und der Kommentare in der Datei selbst an.
- 4. Sie sollten zunächst prüfen, ob ihre Systemumgebung korrekt eingerichtet ist, indem Sie

```
build.sh info bzw. build.cmd info
```

ausführen. Das Ant Build Tool zeigt Ihnen daraufhin die verwendeten JDK- und Ant-Software-Versionen und den generierten CLASSPATH und LIBPATH (für Unix Systeme) an.

- 5. Sollten Sie festgestellt haben, dass Ihr JDK ab 1.4.x eine andere Xalan-Version benutzt (ab 1.4.x ist Xalan im SDK), führen Sie bitte folgende Kommandos aus und prüfen Sie danach Ihr System erneut.
  - cd \$JAVA HOME/jre/lib
  - · mkdir endorsed
  - · cd endorsed
  - cp \$MYCORE HOME/lib/xerces\* .
  - cp \$MYCORE HOME/lib/xalan\* .
  - cd \$JAVA HOME/lib
  - ln -s ../jre/lib/endorsed endorsed
- 6. Eine Übersicht über alle wesentlichen Build-Ziele erhalten Sie mit

#### build.sh usage bzw. build.cmd usage

7. Übersetzen Sie alle MyCoRe Quellcode-Dateien mit dem Befehl

```
build.sh jar bzw. build.cmd jar
```

Dabei entsteht, abhängig von dem von Ihnen gewählten Datenbank-System zur Speicherung der XML-Daten eine Jar-Datei *lib/mycore-for-[cm8—xmldb].jar*.

8. Optional können Sie auch JavaDoc Quellcode-Dokumentation im HTML-Format generieren lassen, indem Sie

build.sh javadocs bzw. build.cmd javadocs aufrufen. Dabei entstehen HTML-Dateien im Verzeichnis documentation/html.

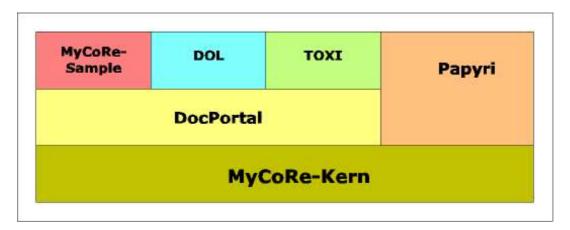
## 3.Die MyCore Beispielanwendung

## 3.1 Grundlegender Aufbau und Ziel der Beispielanwendung

## 3.1.1 Allgemeines

Um die Funktionsweise des MyCoRe-Kernes zu testen wurde eine Beispiel-Anwendung basiered auf diesem Kern entwickelt. Sie soll dem Anwender eine voll funktionsfähige Applikation in die Hand geben, welche eine Vielzahl von Komponenten des MyCoRe-Projektes nutzt und deren Arbeitsweise klar werden lässt. Um die Anwendung, im weiteren MyCoRe-Sample genannt, gleichzeitig sinnvoll einsetzten zu können, wurde als Beispielszenario ein Dokumenten-Server gewählt, wie er bei vielen potentiellen Nutzern zur Anwendung kommt. Auch soll das MyCoRe-Sample die Nachfolge des erfolgreichen MILESS-Dokumenten-Servers sein und den Migrationspfad zu MyCoRe hin aufzeigen.

Die gesammte Applikation ist in mehrere Ebenen aufgeteilt. Dies gestattet eine flexible Konfiguration auf einem Zielsystem bei gleichzeitiger Nutzung mehrerer gleichartiger Anwendungen auf diesem System. Beispielsweise wollen Sie einen Dissertations-Server neben einem Server für eine Bildsammlung und einem allgemeinen Dokumenten-Server auf dem selben System laufen lassen. Alle drei basieren auf DocPortal und nutzen große Teile wie Datenmodell oder Editormasken davon gemeinsam. Diese Komponenten werden in der DocPortal-Basis untergebracht, während die Konfiguration der Tabellennamen jeweils unterschiedlich ist. Die möglichen Szenarien verdeutlicht die folgende Grafik. Für jede Anwendung gibt es im CVS noch eine zugehörige Tomcat-Anwendung welche die vollständige Installation beschleunigen soll.



#### 3.1.2 Datenaufbau

#### MUSS NOCH ÜBERARBEITET WERDEN!!! (Siehe DocPortal)

Analog zum MILESS werden auch hier die Metadaten in drei Gruppen aufgeteilt und von den eigentlichen multimedialen Objekten getrennt behandelt. Zur Modellierung des Datenmodells für die Multimedia-metadaten wurde das allgemein verbreitete Dublin Core Datenmodell herangezogen und umgesetzt. Zur Realisierung wurden folgende Metadaten-Objekte entwickelt:

**Document** - Dieses Objekt beinhaltet die eigentlichen Metadaten des Multimedi-Objektes, in unserem Fall im Dublin Core Format, sowie Verweise auf extern gehaltene Daten wie die drei im

weiteren genannten. Das Datenmodell besteht aus 15 Feldern, zur Speicherung verschiedener Datentypen gibt es atomare Grundkomponenetn. Weiterhin beinhalten die Metaddaten noch Teile zu ihrer Struktur und Verwaltung.

Klassifikation - Hier können lineare oder hierarchich strukturierte Klassifikationen mit ihren Kategorien abgelegt werden. Jeder Verweis auf eine solche Kategorie aus einem Dokument heraus erfolgt mittels der ID der selben und natürlich der ID der Klassifikation als Identifiziererpaar. Für die Gestaltung der Klassifikationen wurde ein eigens Datenmmodel entwicklet.

**LegalEntity** - Auch diese Metadaten sind analog dem **Document** aus atomaren Komponenten zusammengesetzt und repräsentieren natürliche und juristische personen, wie Autoren oder Einrichtunge.

**Derivate** - Hinter diesem Begriff verbergen sich Darstellungsformen der eigentlichen multimedialen Objekte. Beispielsweise können das verschieden Dateiformate eines Images sein. Diese werden an das eigentliche Dokument gebunden.

Eine Übersicht zu den Beziehungen der Objektteile zueinander soll die folgende Grafik vermitteln. Wir haben uns aus den guten Erfahrungen von MILESS herraus entschlossen, diese Aufteilung beizubehalten, da so Einzelkomponeneten in Projekten schon geladen werden können, bevor andere Teile, z. B. das Scannen, abgeschlossen sind.

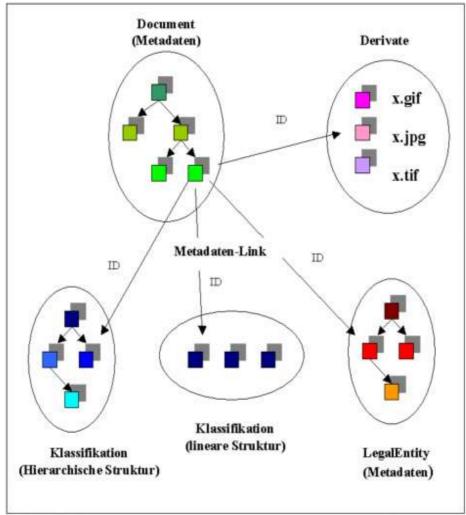


Abbildung 1: Übersicht der Objekte im MyCoRe-Sample

Wie man der Grafik entnehmen kann, ist es möglich, neben Kategorien in Klassifikationen auch Metadaten der Documents und LegalEntities hierarchisch ineinander zu verschachteln. Auf dieser Basis können dann Strukturen wie z. B. die eines Buches abgebildet werden. Alle Beziehungen zwischen den Metadaten sind über eine eindeutige MCRObjectID gelöst.

## 3.1.3 Die MCRObjectID

Dreh- und Angelpunkt aller Beziehungen von Metadaten und der daran angeknüpften Objekte ist ein eindeutiger Identifizierer. Im Falle des MyCoRe Projektes hat dieser den Namen **MCRObjectID** erhalten. Er hat für alle Matadaten einen einheitlichen Aufbau und wird ständig zur Identifizierung genutzt. Auch das API des Systems bietet die Möglichkeit, diese ID automatisch zu generieren. Der Syntax der **MCRObjectID** ist wie folgend festgelegt:

#### MCRObjectID = project\_type\_number

project - Dieses Element der ID spezifiziert ein bestimmtes Projekt. Es dient dazu, Daten verschiedener Projekte, welche sich gemeinsam auf einem System befinden, zu unterscheiden. Der Projektname sollte eindeutig sein und besteht aus einem Wort ohne Sonderzeichen. Achten Sie immer darauf, dass Sie sich bei Vorhaben mit mehreren MyCoRe-Partnern von Anfang an

<sup>9</sup>Siehe Programmers Guide.

auf einen Namen pro Projektteilnehmer verständigen. Für unser Sample haben wir MyCoReDemoDC ausgewählt. Dieser Teil der ID ist case sensitive!

type - Jedem Metadatentyp des Datenmodells ist ein Typbezeichner zuzuordnen. Dieser stellt in MyCoRe die Verbindung von der Konfiguration des Metadatums bis hin zu dessen Suche und Präsentation dar. Der Typname der MCRObjectID wird immer in Kleinbuchstaben (lower case) innerhalb des Systems verwendet. Achten Sie von Anfang an darauf, dies umzusetzen. Im MyCoRe-Projekt gibt es reservierte Typnamen, diese sind

- class für Klassifikationen
- derivate f
  ür Derivate

Zur Umsetzung des Datenmodells wurden weiterhin die Typen **document** für Dokumente und **legalentity** für Personen verwendet. *number* - Dieser Teil dient der Identifizierung des Einzelobjektes. Es dürfen nur natürliche Zahlen angegeben werden. Planen Sie Ihre Vergabe der Nummern bei eigenen Objekten sorgfältig. Da die Nummern teilweise als Strings verarbeitet werden, ist es sinnvoll, sie mit einer ausreichenden Zahl von Vornullen zu versehen. Dies erledigt das MyCoRe-System automatisch unter Zuhilfenahme des Konfogurationswertes MCR.metadata objectid number pattern im File *mycore.properties.private*.

## 3.1.4 Benutzer, Gruppen und Privilegien

Im Benutzermanagement werden diejenigen Personen verwaltet, die mit dem System umgehen (zum Beispiel als Autoren Dokumente einstellen). Dazu bietet die Benutzerverwaltung insbesondere die Möglichkeit, dass sich Benutzer und Benutzerinnen am System authentifizieren können.

Die Geschäftsprozesse einer Benutzerverwaltung wie zum Beispiel das Anlegen neuer Benutzer, das Setzen von Passwörtern, das Deaktivieren von Benutzern usw. erfordern unterschiedliche Privilegien. Das MyCoRe-User-Management ermöglicht eine detaillierte Vergabe von Privilegien auf der Basis von Benutzergruppen. Dadurch wird es zur Entlastung der Betreiber der Digitalen Bibliothek möglich, dediziert administrative Privilegien an Kunden zu übertragen und damit administrative Aufgaben zu delegieren.

Das Benutzermodell ist schematisch in Abbildung 2 dargestellt. Gruppen können sowohl Benutzer und Benutzerinnen als auch andere Gruppen als Mitglieder haben. Weiterhin wird jeder Gruppe eine Liste von Privilegien zugewiesen. Benutzer übernehmen die Privilegien von den Gruppen und können damit nachweisen, dass sie das Recht haben, bestimmte Aktionen durchzuführen. Dabei werden Privilegien auch hierarchisch weiter gegeben: Hat eine Gruppe eine andere Gruppe als Mitglied, so erhalten auch die Mitglieder dieser Gruppe (das können wiederum sowohl Benutzer als auch Gruppen sein) die Privilegien der ersten Gruppe

Neben den Mitgliedern und Privilegien hat eine Gruppe mindestens einen Administrator. Dies kann auch wiederum eine Gruppe sein. Ist es eine Gruppe, so haben alle direkten Benutzer und Benutzerinnen der Gruppe administrative Rechte für die Gruppe, mit der sie alle Geschäftsprozesse für diese Gruppe durchführen dürfen. Diese Rechte werden nicht an Mitgliedsgruppen der administrativen Gruppe weiter vererbt.

Das Privilegienmodell dient der Rollenübernahme im MyCoRe-System. Es darf nicht mit der Zugriffskontrolle auf Objekte in der Digitalen Bibliothek verwechselt werden. Ein Privileg benötigt ein Benutzer des Systems zum Beispiel dann, wenn ein Objekt in der Bibliothek (z.B. ein

Dokument, ein Derivat und natürlich auch weitere Benutzer, Gruppen oder Privilegien) erstellt werden soll. Die Zugriffskontroll-Komponente kann nach der Erzeugung eines Objekts die weitere Kontrolle regeln.

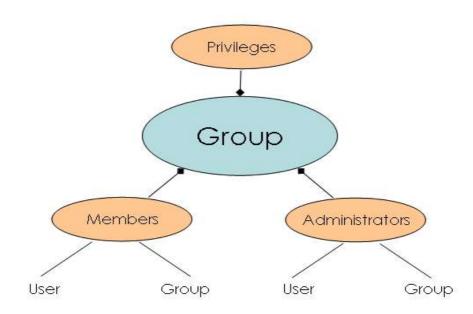


Abbildung 2: Schematisches Gruppenmodell

In der Version 0.9 der MyCoRE-Sample Anwendung werden Daten über Benutzer, Gruppen und Privilegien in Form von XML-Dateien mitgeliefert. Diese dienen zum Testen und zur Demonstration der Komponente. Zur Version 1.0 wird ein kompletteres, für einen Dokumentenserver typisches Modell vorbereitet

Da die Benutzerverwaltung eine Kernfunktion von MyCoRe ist, wird sie ausführlich im ProgrammerGuide beschrieben. Dort finden Sie auch die Syntaxen der XML-Beschreibungen der Benutzer, Gruppen und Privilegien.

## 3.1.5 Das Sample-Datenmodell

## MUSS NOCH ÜBERARBEITET WERDEN!!! (Siehe DocPortal)

Das Datenmodell des MyCoRe-Samples soll exemplarisch einen kleinen Dokument-Server abbilden, wie er dann für große Lösungen übernommen werden kann. Dabei sollen Multimediale Objekte verschiedenster Art und Herkunft gemeinsam verwaltet werden. Als Grundgerüst für die Dokumente diente uns das Dublin Core Datenmodell, welches in einigen Punkten inhaltlich etwas nach unseren Auffassungen angepasst wurde. Das Personen-Datenmodell ist hingegen derzeit propitär. Ggf. kommen hier in einer späteren Version von MyCoRe Standard-Datenmodelle zum Einsatz. Die Klassifikationen sind hierarchisch angelegt, d. h. Kategorien können wieder Unterkategorien beherbergen. Im folgenden werden die einzelnen Felder des Metadatenmodelles beschrieben und es wird aufgezeigt, welche Suchen vorgesehen sind. Dabei bedeutet PS - parametrische Suche, TS - Volltextsuche. Eine genaue Beschreibung der Suchmechanismen finden Sie im Programmers Guide.

## 3.1.5.1 Die Klassifikationen (Classifications)

Für das Datenmodell sind die folgenden Klassifikationen vorgesehen. Alle Label und Descriptions der einzelnen Kategorien können dabei in mehreren Sprachen angegeben werden.

- Format enthält eine einfache Liste der möglichen Formate des Dokumentes.
- Typen enthält eine einfache Liste der möglichen Typen des Dokumente.
- Eigner enthält eine hierarchiche Liste aller möglichen Eignergruppen eines Dokumentes.

## 3.1.5.2 Das Dokument (Document)

Bezeichner	Тур	Beschreibung	
Title	MCRMetaLangText	Titel des Werkes, alternativer Titel usw. in mehreren Sprachen.	
Creator	MCRMetaLinkID	Enthält einen oder mehrere Verweise auf den/die Autor(en) des Werkes.	
Subject	MCRMetaClassification	Enthält Verweise auf Klassifikationen , die das Werk in Kategorien einstufen.	
Description	MCRMetaLangText	Enthält eine Kurzbeschreibung des Inhaltes, ggf. in mehreren Sprachen.	
Publisher	MCRMetaLinkID	Enthält einen oder mehrere Verweise auf den/die an der Publikation beteiligten des Werkes.	
Contributor	MCRMetaLinkID	Enthält einen oder mehrere Verweise auf den/die weiteren Beteiligten des Werkes.	
Date	MCRMetaDate	Enthält das Erscheinungsdatum des Werkes.	
Туре	MCRMetaClassification	Enthält einen Verweis auf Klassifikation, die das Werk in eine Type-Kategorien einstuft.	
Format	MCRMetaClassification	Enthält einen Verweis auf Klassifikation, die das Werk in eine Format-Kategorien einstuft.	
Identifier	MCRMetaLangText	Enthält eine Identifikationsmerkmale wie Inventarnummern usw., ggf. in mehreren Sprachen.	
Source	MCRMetaLangText	Enthält eine Quellenangabe, ggf. in mehreren Sprachen.	
Keywords	MCRMetaLangText	Enthält eine Schlüsselwortes, ggf. in mehreren Sprachen.	
Coverage	MCRMetaLangText	Enthält eine Erstreckung, ggf. in mehreren Sprachen.	
Rights	MCRMetaLangText	Enthält eine Rechtebeschreibung, ggf. in mehreren Sprachen.	

**Tabelle 4:** MyCoRe Document Datenmodell

Relativer XPath	parametric search	text search
ID	•	-
label	•	-
structure/derobjects/derobject	•	-
structure/parents/parent	-	-
structure/children/child	-	-
metadata/titles/title	•	•
metadata/creators/creator	•	-
metadata/subjects/subject	•	-
metadata/descriptions/description	•	•
metadata/publishers/publisher	•	-
metadata/contributors/contributor	•	-
metadata/dates/date	•	-
metadata/types/type	•	-
metadata/formats/format	•	-
metadata/identifiers/idetifier	•	-

Relativer XPath	parametric search	text search
metadata/sources/source	-	-
metadata/keywords/keyword	•	•
metadata/coverages/coverage	•	•
metadata/rights/right	•	-
service/servflags/servflag	•	-
services/servdates/servdate	•	-

Tabelle 5: MyCoRe Document Suchschema

## 3.1.5.3 Die Personendaten (LegalEntities)

Bezeichner	Тур	Beschreibung
Person	MCRMetaPerson	Name der Person mit akademischen Titel, Adelstitel usw.
Corporation	MCRMetaCorporation	Name einer Institution oder Einrichtung mit Abteilungsbezeichnung usw.
Address	MCRMetaAdress	Die Adresse mit Land, Staat, ort, PLZ, Straße und Nummer.
Date	MCRMetaDate	Datumsangaben wie Geburtstag.
Phone	MCRMetaLangText	Telefonnummern
WEB	MCRMetaLangText	Eine oder mehrere URS's.
eMail	MCRMetaLangText	Eine oder mehrere eMail Adressen.

**Tabelle 6:** MyCoRe LegalEntity Datenmodell

Relativer XPath	parametric search	text search
ID	•	-
label	•	-
structure/derobjects/derobject	•	-
structure/parents/parent	-	-
structure/children/child	-	-
metadata/persons/person	•	•
metadata/corporations/corporation	•	•
metadata/adresses/address	•	-
metadata/dates/date	•	-
metadata/phones/phone	-	-
metadata/webs/web	-	-
metadata/emails/email	-	-
service/servflags/servflag	•	-
services/servdates/servdate	•	-

Tabelle 7: MyCoRe LegalEntity Suchschema

## 3.2 Download der Beispielanwendung

Nachdem Sie den MyCoRe-Kern erfolgreich installiert haben, ist nun die Installation der mitgelieferten Beispiel-Anwendung sinnvoll. Hier können Sie ein erstes Gefühl dafür gewinnen, wie eine eigene Anwendung gestaltet sein könnte. Das MyCoRe Sample wird für alle unterstützten Systeme über das CVS Repository ausgeliefert.

Derzeit steht das MyCoRe-Beispiel nicht unter <u>www.mycore.de</u>, da es sich hierbei um die reduzierte Version einer in Produktion laufenden Anwendung handelt. Sie müssen also zuerst ein kleines Shell-Script cvslpz.sh erstellen, welches die erforderlichen Variablen setzt.

```
#Script zum Zugriff auf das CVS in Leipzig
export CVS_CLIENT_LOG=~/cvs_log
export TERM=vt100
export CVS_ROOT=:pserver:anoncvs@cvs.dl.uni-leipzig.de:/work/cvs
export CVS_RSH=ssh
cvs $*
```

Führen Sie zuerst folgendes Kommando aus (das Passwort ist anoncvs)

```
cvslpz.sh login
```

Das Holen der aktuellen Version von **DocPortal** und **MyCoReSample** erfolgt mit den Kommandos

```
cvslpz.sh checkout docportal
cvslpz.sh checkout mycoresample
```

Nach erfolgreichem CheckOut finden Sie nun zwei Verzeichnisse – docportal für die DocPortal-Basis-Applikation und mycoresample als spezielle Applikation. Der folgende Abschnitt beschreibt deren Konfiguration.

## 3.3 Konfiguration zur Arbeit mit den Beispieldaten

## MUSS NOCH ÜBERARBEITET WERDEN!!! (Siehe DocPortal)

## 3.3.1 Grundlegende Konfigurationen

Dieser Abschnitt beschäftigt sich mit der Konfiguration der Beispielanwendung in allgemeinen Bereichen wie JDBC, Logger, usw. Die MyCoRe Konfigurationen für das Beispiel finden Sie im Verzeichnis *mycore-sample-application/config*. In diesem Verzeichnis finden Sie eine Datei *mycore.properties.priv\_template*. Diese müssen Sie nach *mycore.properties.private* kopieren. Sie enthält alle Konfigurationsparameter, die für eine erste Installation und eine direkte Übernahme des Beispiels in eine Produktionsumgebung angepasst werden müssen. Alle Beschreibungen in diesem Punkt beziehen sich auf dieses File.

## 3.3.1.1 Pfade und Systemumgebung anpassen

Auch für die Zusammenstellung und Installation der Beispiel-Anwendung verwendet MyCoRe das Apache Ant Build-Tool. Entsprechend der Installationsanleitung des Ant-Paketes sollten Sie zunächst die Umgebungsvariablen JAVA\_HOME und ANT\_HOME gesetzt haben. Sollten diese Variablen auf Ihrem System noch nicht gesetzt sein, können Sie dies in der Datei build.sh (Unix) bzw. build.cmd (Windows) nachholen und korrigieren.

Die MyCoRe Beispiel-Anwendung verwendet die Dateien aus dem MyCore Kern, insbesondere die

erzeugte Datei *mycore-for[cm8—xmldb].jar* und die Konfigurationsdatei für den Build-Prozess *build.properties*.

Sie sollten zunächst prüfen, ob ihre Systemumgebung korrekt eingerichtet ist, indem Sie

```
build.sh info bzw. build.cmd info
```

ausführen. Das Ant Build Tool zeigt Ihnen daraufhin die verwendeten JDK- und Ant-Software-Versionen und den generierten CLASSPATH und LIBPATH (für Unix Systeme) an. Eine Übersicht über alle wesentlichen Build-Ziele erhalten Sie mit

build.sh usage bzw. build.cmd usage

## 3.3.1.2 JDBC-Treiber konfigurieren

Im MyCoRe-Projekt werden ein Teil der Organisations- und Metadaten in klassischen relationalen Datenbanken gespeichert. Um die Arbeit mit verschiedenen Anbietern möglichst einfach zu gestalten, wurde die Arbeit mit dieser Datenbank gegen die JDBC-Schnittstellen programmiert.

In der Konfigurationsdatei *mycore.properties.private* legen Sie im Parameter MCR.persistence\_sql\_driver fest, welcher JDBC-Treiber verwendet werden soll. Weiterhin müssen Sie die Variable MCR.persistence\_sql\_database\_url anpassen, die die JDBC URL für Verbindungen zu Ihrer Datenbank festlegt. Der DB2 Library-Name LIB muss durch den aktuellen (z. B. ICMNLSDB) ersetzt werden. Analog dazu muss der User ODBC bei MySQL durch den entsprechenden Nutzer (z. B. mcradmin) ersetzt werden. Beachten Sie dabei insbesondere, dass meist Gross/Kleinschreibung relevant ist! Weiterhin können Sie die minimale und maximale Anzahl der gleichzeitigen Verbindungen zur Datenbank festlegen.

```
# JDBC parameters for connecting to DB2
#MCR.persistence_sql_database_url=jdbc:db2:LIB
#MCR.persistence_sql_driver=COM.ibm.db2.jdbc.app.DB2Driver

# JDBC parameters for connecting to MySQL
MCR.persistence_sql_database_url=jdbc:mysql://localhost/mycore?user=ODBC
MCR.persistence_sql_driver=org.gjt.mm.mysql.Driver

MCR.persistence_sql_init_connections=1
MCR.persistence_sql_max_connections=5
```

## 3.3.1.3 Debug konfigurieren

Innerhalb des MyCoRe-Projektes wird zum Erzeugen aller Print-Ausgaben für das Commandline-Tool und/oder die Stdout-Logs das externe Paket **log4j**des Apache-Jakarta-Projektes benutzt<sup>10</sup>. Dieses ist mittlerweile ein Quasistandard und ermöglicht eine gezielte Steuerung der Informationen, welche man erhalten möchte. In der Grundkonfiguration in mycore.properties.private ist der Output-Level INFO eingestellt. Eine zweite Standardvorgabe ist DEBUG, diese ist auskommentiert und kann alternativ bei Problemen genommen werden. **log4j** bietet jedoch darüber hinaus noch viele weitere Möglichkeiten, die Sie bitte der Dokumentation zu diesem Produkt entnehmen. Ergänzend sei auch auf das MyCoRe-Konfigurationsfile mycore.properties.logger hingewiesen.

```
\# Set the log level and appender for the general logger
```

<sup>10</sup>http://jakarta.apache.org/log4j/docs/index2.html

```
MCR.log4j.rootLogger=INFO, stdout
#MCR.log4j.rootLogger=DEBUG, stdout
```

## 3.3.1.4 Metadaten-Store konfigurieren

Den Typ des zur Laufzeit des Systems zu nutzenden Metadaten-Store konfigurieren haben Sie bereits in der Datei \$MYCORE\_HOME/bin/build.properties über den Parameter MCR.XMLStore.Type festgelegt. Dabei sind die Werte cm8 für IBM Content Manager 8, oder xmldb für eine XML:DB kompatible XML-Datenbank wie eXist oder Tamino (Software AG) möglich<sup>11</sup>. Die MyCoRe Beispiel-Anwendung verwendet automatisch diese Konfiguration, sie müssen nun nur noch die Parameter der einzelnen XML-Stores konfigurieren.

## 3.3.1.5 Konfiguration von IBM Content Manager 8.2

Falls Sie MCR.XMLStore.Type=cm8 verwenden, passen Sie in der Datei mycore.properties.private die Variablen MCR.persistence\_cm8\_\* an. Die Einträge sind eigentlich selbsterklärend, so dass an dieser Stelle auf weitere Erläuterungen verzichtet werden kann.

```
# Special values for the persistence layer
MCR.persistence_cm8_max_connections=2
MCR.persistence_cm8_library_server=ICMNLSDB
MCR.persistence_cm8_user_id=icmadmin
MCR.persistence_cm8_password=???????

# Special values for the text search engine
MCR.persistence_cm8_textsearch_ccsid=819
MCR.persistence_cm8_textsearch_lang=DE_DE
MCR.persistence_cm8_textsearch_indexdir=/home/db2inst1/sqllib/db2ext/indexes
MCR.persistence_cm8_textsearch_workingdir=/home/db2inst1/sqllib/db2ext/indexes
```

Da der Persitence Layer CM8 auf einem Mapping der XML-Daten nach DB2 besteht, müssen die CM8 ItemTypes vor dem Laden der Daten separat angelegt werden. Dies geschiet mittels

```
build.sh create.metastore bzw. build.cmd create.metastore
```

#### 3.3.1.6 Die Nutzung von eXist als XML:DB Backend

Falls Sie MCR.XMLStore.Type=xmldb verwenden, passen Sie in der Datei mycore.properties.private die Variablen MCR.persistence\_xmldb\_driver und MCR.persistence\_xmldb\_database\_url an. Die folgenden Zeilen sind für Nutzer der freien Software eXist gedacht. Sollten Sie eine andere XML:DB benutzen, passen sie die Daten bitte entsprechend den Erfordernissen an.

```
MCR.persistence_xmldb_driver=org.exist.xmldb.DatabaseImpl
MCR.persistence_xmldb_database_url=xmldb:exist://localhost:8081/db/mycore
MCR.persistence_xmldb_database=exist
```

Die folgenden Zeilen sind für Nutzer der freien Software eXist gedacht. Sollten Sie eine andere XML:DB benutzen, passen sie die Daten bitte entsprechend den Erfordernissen an. Starten Sie nun

<sup>11</sup> Zur Nutzung von Tamino konsultieren Sie bitte die gesonderte Dokumentation.

den eXist-Client (<*eXist-installdir*>/*bin/client.sh* bzw. *cliend.cmd*) und führe Sie folgende Kommandos zum anlegen der Stores unter eXist aus:

```
mkcol mycore
chown guest guest mycore
cd mycore
mkcol legalentity
chown guest guest legalentity
mkcol document
chown guest guest document
mkcol derivate
chown guest guest derivate
quit
```

## 3.3.1.7 Speicherung von Dokumenten konfigurieren

Neben den Metadaten sind im Sample auch eine Reihe von Dokumenten und Bildern zum Laden in die Beispielanwendung abgelegt.

## 3.3.1.7.1 File System Store

In der Grundkonfiguration verwendet die Beispiel-Applikation zur Speicherung der Datei-Inhalte der Derivate das lokale Dateisystem. Passen Sie in der Datei mycore.properties.private die Variable MCR.IFS.ContentStore.FS.BaseDirectory an und erzeugen Sie ein neues, leeres Verzeichnis am angegebenen Ort.

#### **3.3.1.7.2** Lucene Store

Sollten sie in der freien Variante noch die Textindizierung für \*.txt und \*.pdf mittels Lucene wünschen, so sind noch folgende Dinge zu tun:

- 1.build.sh jar
- 2. Setzen Sie die nachfolgenden Variablen in mycore.properties.private auf die richtigen Werten. Dabei kann das Lucene.BaseDirectory auf das selbe Verzeichnis verweisen wie der File System Store.

```
MCR.PluginDirectory
MCR.IFS.ContentStore.Lucene.IndexDirectory
MCR.IFS.ContentStore.Lucene.BaseDirectory
```

- 3. Erzeugen Sie nun noch die eingetragenen Verzeichnisse.
- 4. Als letztes muss noch in der Datei ContentStoreSelectionRules.xml die Sektion für den Lucene-Store aktiviert werden.

#### 3.3.1.7.3 CM8 Store

Die Speicherung der Dokumente im IBM Content Manager bietet die Möglichkeit einer automatischen Textindizierung. Dazu müssen aber alle Konfigurationen für die Nutzung des TextSearch Extenders gesetzt werden. Genaue Hinweise zur Installation finden Sie in einem gesonderten Dokument der Rubrik **Quick Guide**.

#### 3.3.2 Laden der Beispiel-Inhalte

1. Laden Sie die Benutzer, Gruppen und Privilegien für die Beispielanwendung mit build.sh load.users bzw. build.cmd load.users

2. Laden Sie die Beispiel-Klassifikationen mit

build.sh load.classifications bzw.

build.cmd load.classifications

3. Laden Sie die Personen-, Autoren- und Kontaktdaten der Beispiel-Anwendung mit

build.sh load.legalentities bzw.

build.cmd load.legalentities

4. Laden Sie die Dokumenten-Metadaten der Beispiel-Anwendung mit

build.sh load.documents bzw.

build.cmd load.documents

5. Laden Sie die Dokumenten-Derivate mit den dazugehörigen Dateien mit

build.sh load.derivates bzw. build.cmd load.derivates

## 3.4 Arbeiten mit dem MyCoRe Command Line Interface

## 3.4.1 Erzeugen der Skripte mycore.sh / mycore.cmd

Neben dem MyCoRe-Web-Interface kann für administrative Zwecke das MyCoRe Command Line Interface (CLI) genutzt werden. Zum Aufruf des CLI müssen Sie zunächst die erforderlichen Shell-Skripte erzeugen:

build.sh scripts bzw. build.cmd scripts

Dieser Aufruf generiert die Shell-Skripte bin/mycore.sh (Unix) bzw. bin/mycore.cmd (Windows).

#### 3.4.2 Aufruf des CommandLineInterface

Starten Sie das MyCoRe Command Line Interface durch Aufruf von bin/mycore.sh (Unix) bzw. bin/mycore.cmd (Windows). Sie erhalten eine Übersicht über die verfügbaren Befehle durch Eingabe von help . Sie verlassen das CommandLineInterface durch Eingabe von quit oder exit .

#### 3.4.3 Tests auf der Basis des CommandLineInterface

Nachdem Sie nun die Testdaten geladen haben, besteht schon einmal die Möglichkeit, zu testen, ob die geladenen Daten sich anfassen lassen. Hierzu können sie das ConnamdLineInterface benutzen. Starten Sie bin/mycore.sh (Unix) bzw. bin/mycore.cmd (Windows) und versuchen Sie zum Beispiel folgende Kommandos:

```
login gandalf
alleswirdgut
list all users
list all groups
list all privileges

query local class /mycoreclass[@ID="MyCoReDemoDC_class_0002"]
query local document /mycoreobject[@ID="MyCoReDemoDC_document_0001"]
save derivate MyCoReDemoDC derivate 0002 to derivate 2
```

## 3.5 Die Zusammenarbeit mit anderen MyCoRe-Sample-Installationen

Das MyCoRe-System ist so konzipiert, dass hinsichtlich der Metadaten gleichartige Installationen miteinander arbeiten können und von einer gemeinsamen Oberfächer (Frontend) abgefragt werden können. Hierzu müssen die Remote-Instanzen definiert werden. Auch die eigene Installation kann über diesen Weg abgefragt werden. Voraussetzung ist die im Abschitt 'Erzeugen und Konfigurieren der Web-Anwendung' beschriebene Installation eines Web Application Servers, welcher für die Remote-Zugriffe via Servlets zuständig ist.

## 3.5.1 Die eigene Installation

Die Konfiguration für die eigene Installation finden Sie im File mycore.properties.private. Hier muss im Normalfall nur die Hostadresse und ggf. der Port geändert werden, alle anderen Angaben sollten übernommen werden können.

```
# Configuration for the own host with remote access
MCR.remoteaccess_remote_query_class=org.mycore.backend.remote.MCRServletCommunic
ation
MCR.remoteaccess_remote_host=pcclu02.rz.uni-leipzig.de
MCR.remoteaccess_remote_protocol=http
MCR.remoteaccess_remote_port=8080
MCR.remoteaccess_remote_query_servlet=/mycoresample/servlets/MCRQueryServlet
MCR.remoteaccess_remote_ifs_servlet=/mycoresample/servlets/MCRFileNodeServlet
```

## 3.5.2 Standard-Server des MyCoRe-Projektes

Von den Entwicklern des MyCoRe-Projektes werden exemplarisch einige MyCoRe-Sample-Installationen bereitgehalten. Diese sind im Konfigurationsfile mycore.properties.remote notiert und sollten in der Regel verfügbar sein. Sie repräsentieren eine Auswahl der verschieden Persistence-Layer. Auch die Auswahl für die Suche in diesen Instanzen ist bereits in das Sample integriert und solle nach dem erfolgreichen Start der Web Applikation aktiv sein.

Alias	URL	Port	Standort
mcrLpzHHttp	http://ibmdlh.rz.uni-leipzig.de/mycoresample	8080	Uni Leipzig
mcrGreiHttp	http://mycoresample.rz.uni-greifswald.de/mycoresample	80	Uni Greifswald

**Tabelle 8:** Feste Test-Instanzen für das MyCoRe-Beispiel

## 3.6 Erzeugen und Konfigurieren der Web-Anwendung

## 3.6.1 Erzeugen der Web-Anwendung

Durch Eingabe von

```
build.sh webapp bzw. build.cmd webapp
```

wird die MyCoRe Sample Web Application im Verzeichnis webapps erzeugt. Alternativ können Sie auch ein Web Application Archive (war) erzeugen, indem Sie

build.sh war bzw. build.cmd war

aufrufen.

Das MyCoRe Build-Script kopiert beim Erzeugen der Web Applikation auch alle externen, erforderlichen jar-Dateien Ihrer verwendeten Datenbank-Systeme (IBM Content Manager / DB2,

MySQL, eXist) in das Verzeichnis WEB-INF/lib, entsprechend den Vorgaben Ihrer Konfiguration in build.properties. Beachten Sie dazu bitte die Hinweise in der Ausgabe beim Erzeugen der Web Application.

## 3.6.2 Konfiguration des Web Application Server

#### 3.6.2.1 Tomcat

Die grundlegende Installation von Tomcat wurde bereits beschrieben. Nun soll auf dieser Basis das die WEB-Anwendung des MyCoRe-Samples installiert werden. Dabei ist an dieser Stelle nur ein einfaches Szenario auf der Basis der Tomcat-Grundinstallation beschrieben. Für die Konfiguration komplexerer Modelle, z. B. mehrere Applikationen nebeneinander, gibt es weiter hinten in diesem Dokument eine ausführliche Anleitung. Achtung, auch Tomcat bringt eigene Xeces/Xalan Archive mit sich. Sollten Sie diese im JDK bereits ersetzt haben, so müssen Sie die mit MyCoRe gelieferte Version auch unter TOMCAT\_HOME/common/endorsed stellen und die alten Dateien löschen.

Folgende Schritte sind auszuführen:

- 1. su -
- 2. cd \$CATALINA\_HOME/webapps
- 3. cp \$MYCORE SAMPLE HOME/mycoresample.war
- 4. rctomcat restart

Nun sollten Sie auf die Beispielanwendung mit der URL http://localhost:8080/mycoresample zugreifen können. Testen Sie nun die Anwendung!

## 3.6.2.2 Websphere

In der gesonderten Dokumentation zur Installation des IBM Content Managers wurde ja bereits beschrieben, wie die Anwendung IBM WebSphere zu installieren ist. Diese soll als Servlet-Engine zur Anwendung kommen, wenn der IBM Content Manager 8 als Persitence-Layer verwendet wird. Die Konfiguration von WebSphere erfolgt via Web-Anwendung. Starten Sie dazu den Adminserver mittels

/usr/WebSphere/AppServer/bin/startServer.sh server1

Öffnen Sie nun eine Web-Browser mit der URL http://<hostname>:9090/admin und melden Sie sich an. Nun sind folgende Schritte durchzuführen:

- 1. (linke Seite) Server Application Server
- 2. (rechte Seite) NEW
- 3. (rechte Seite) Server Name mycoresample NEXT
- 4. (rechte Seite) FINISH
- 5. (linke Seite) Applications Install New Applications
- 6. (rechte Seite) **Server Path** Pfad zum File mycoresample.war eintagen /mycoresample im Feld Context Root eintragen **NEXT**
- 7. (rechte Seite) Preparing for application installation **NEXT**
- 8. (rechte Seite) Step 1 NEXT
- 9. (rechte Seite) Step 2 NEXT
- 10.(rechte Seite) Step 3 Auswählen mycoresample in der Checkbox dann auswählen der Zeile mit server=mycoresample APPLY
- 11.(rechte Seite) Step 3 NEXT

12.(rechte Seite) Step 4 FINISH

13.(linke Seite) Server Application Server

14.(rechte Seite) mycoresample Process Definition Process Execution

15.(rechte Seite) User auf mcradmin setzen

16.(rechte Seite) Group auf mcr setzen

17.(rechte Seite) APPLY OK

18.(rechte Seite) Java Virtual Machine Classpath

19.(rechte Seite) einfügen der Pfade

/home/db2inst1/sqllib/java12/db2java.zip:

/usr/lpp/cmb/lib/cmbsdk81.jar:

/usr/lpp/cmb/cmgmt

20.(rechte Seite) APPLY OK

21.(rechte Seite) oben auf den Text save klicken

22.(rechte Seite) SAVE

23.(linke Seite) Environment Update Web Server Plugin OK

24.Logout

Nun muss der Application Server gestartet werden:

/usr/WebSphere/AppServer/bin/startServer.sh mycoresample

Da die Anwendung als **mcradmin** ausgeführt wird, kommt es zu einem Schreibfehler in den Log-Files. Hier ist nun folgendes zu tun:

- 1. chown -R mcradmin:mcr /usr/WebSphere/AppServer/logs/mycoresample
- 2. chmod 666 /usr/WebSphere/AppServer/logs/activity.log
- 3. cd/usr/WebSphere/AppServer/temp/<hostname>
- 4. mkdir mycoresample
- 5. chown -R mcradmin:mcr mycoresample

Danach ist der Server nocheinmal zu stoppen und neu zu starten:

```
/usr/WebSphere/AppServer/bin/stopServer.sh mycoresample /usr/WebSphere/AppServer/bin/startServer.sh mycoresample
```

Jetzt sollten Sie auf das MyCoRe-Sample unter der URL http://<hostname>/mycoresample zugreifen können.

## 4. Vom Sample zum eigenen Dokumenten-Server

## 4.1 Allgemeines

Nachdem das Sample bei Ihnen nun läuft und erste Erfahrungen damit gesammelt wurden, soll nun auf dieser Grundlage aufbauend ein produktiver Dokumenten-Server aufgesetzt werden. Hier gilt es nun, das MyCoRe Modell in eine praxisorientierte Anwendung umzusetzen. Sicher werden bei jedem Anwender weitere zusätzliche Anforderungen auftreten, welche innerhalb des Beispiels oder der nachfolgenden Ausführungen keine Beachtung fanden. Die MyCoRe-Gruppe ist gern bereit, allgemeingültige Ergänzungen in das Kern-Projekt mit aufzunehmen.

Für die Erstellung einer Dokument- und Multimedia-Server-Anwendung sind im groben die folgenden Schritte erforderlich. Modifizieren Sie das Beispiel schrittweise hin zu Ihrer eigenen Applikation. Prüfen Sie in Zwischenschritten immer, dass die gewünschte Funktionalität noch erhalten geblieben ist.

- Kopieren des MyCoRe-Samples in einen gesonderten Verzeichniszweig (z. B. ~/docserv. Es ist von Vorteil diesen Pfad auch in einer Environment Variable abzulegen (z. B. export DOCSERV HOME=~/docserv).
- Legen Sie für Ihre Anwendung die Namen für die Datenbank-Tabellen, XML- und IFS-Stores fest und ändern Sie die Konfigurations-Dateien entsprechend. Erzeugen Sie nun die Data Stores und XML-Schema Files.
- Modifizieren Sie die User-Daten entsprechend ihren Anforderungen und laden Sie das User-System.
- Erstellen Sie sich alle benötigten Klassifikationen (z. B. eine aller Ihrer Einrichtungen) und laden Sie diese.
- Laden Sie nun erste, per Hand oder Script erstellte Metadaten-Test-Files und laden Sie auch diese. Nun können Sie auf Commandline-Ebene schon mittels mycore.sh bzw. mycore.cmd Anfragen an das System stellen und erste Test durchführen.
- Legen Sie die Stores für die Multimedia-Objekte fest, konfigureieren Sie diese und laden Sie einige Beispiele zum Test.
- Legen Sie nun eine URL für ihren Server fest und setzen Sie einen Web-Server (WebSphere oder Apache/Tomcat) auf.
- Installiern Sie Ihre Anwendung im Web-Server und modifizieren Sie schrittweise die Präsentation nach Ihren Bedürfnissen.
- Testen und integrieren Sie die in diesem Kapitel beschriebenen weiterfführenden Funktionalitäten, welche nicht im MyCoRe-Sample enthalten sind.

Habe Sie all die Schritte bewältigt, sollte Ihnen nun ein ansprechender Dokument-Server zur Verfügung stehen. Sollten Sie andere Applikationen, wie Sammlungen usw. aufbauen wollen, konsultieren Sie bitte auch das ProgrammerGuide, wo auf derartige MyCoRe-Erweiterungen näher eingegangen wir.

## 4.2 XML-Syntax des Datenmodells

In diesem Abschnitt wird der Syntax der einzelnen XML-Daten-Dateien und der MyCoRe-

Standard-Datentypen näher beschrieben. Die Kenntnis des Syntax benötigen Sie um eigene Datensätze für Ihren Dokumenten-Server zu erstellen. Eine umfassende Beschreibung der zugehörigen Klassen finden Sie im Programmer Guide. In den folgenden Abschnitten wird lediglich auf die XML-Syntax der Daten eingegangen.

#### 4.2.1 Das Klassifikationen-Datenmodell

Wie bereits erwähnt dienen Klassifikationen der einheitlichen Gliederung bestimmter Fakten. Sie sorgen dafür, dass eine einheitliche Schreibweise für bestimmte Begriffe verwendet wird. Diese Einzelbegriffe werden als Kategorien bezeichnet. Innerhalb einer Kategorie kann der Begriff in verschiedenen Sprachen aufgezeichnet sein. Die eindeutige Zuordnung zu einer Kategorie erfolgt über einen Bezeichner. Dieser besteht aus der Klassifikations- und Kategorie-ID und muss eindeutig sein.

Klassifikationen werden im MyCore-Sample als extra XML-Datei erstellt, in die Anwendung importiert und in Form einer Datenbank gespeichert. Dies ist für den Nutzer transparent und erfolgt mittels Schnittstellen. Der Zugriff auf die Daten erfolgt dann durch den oben genannten Bezeichner. Die Klassifikations-ID ist eine MCRObjectID mit dem Typ class. Die Kategorie-ID ist dagegen frei wählbar. Sie darf mehrstufig ein, jede Stufe spiegelt eine Hierarchieebene wieder. Die Stufen in der ID werden mit einem Punkt voneinander getrennt, 'Uni.URZ'. Das wiederum gestattet eine Abfrage nach allen untergeordneten Stufen bzw. Sub-Kategorien wie 'Uni.\*'. Achtung, sollten Sie Zahlen als Kategorie-ID's mit verwenden, so planen Sie entsprechende Vornullen ein, andernfalls wird das Suchergebnis fehlerhaft! Weiterhin ist es sehr zu empfehlen, dieser Zahlenfolge einen Buchstaben voranzusetzen, damit die ID nicht als Zahl interpretiert wird (z. B. beim Content Manager 8.2).

Im ID Attribut einer category ist der eindeutige Bezeichner anzugeben. Das darunter befindliche label Tag bietet die Möglichkeit, eine Kurzbezeichnung anzugeben. Mehrsprachige Ausführungen sind erlaubt. Dasselbe gilt für das Tag description. Beide Werte werden als Strings aufgefasst. Eine category kann wiederum category Tags beinhalten.

Abbildung 3: XML-Syntax eines Klassifikations-Objektes

```
<?xml version="1.0" cncoding="ISO-8859-1" ?>
<mycoreclass
 xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
 xsi:noNamespaceSchemaLocation="MCRClassification.xsd"
 xmlns:xlink="http://www.w3.org/1999/xlink"
 ID="..."
 <label xml:lang="..." text="..." description="..."/>
 <categories>
  <category ID="...">
   <label xml:lang="..." text="..." description="..."/>
   <category ID="...">
    <label xml:lang="..." text="..." description="..."/>
   </category>
   <category ID="...">
    <label xml:lang="..." text="..." description="..."/>
   </category>
  </category>
  <category ID="...">
   <label xml:lang="..." text="..." description="..."/>
  </category>
 </categories>
</mycoreclass>
```

#### 4.2.2 Das Metadatenmodell

Die zu speichernden Daten des Beispiels teilen sich in unserem Modell in Metadaten und digitale Objekte. Dies gilt auch für die vom Anwender entwickelten Applikationen. Digitale Objekte sind Gegenstand des Abschnitts 'IFS und Content Store'. Unter Metadaten verstehen wir in MyCoRe alle beschreibenden Daten des Objektes, die extern hinzugefügt, separat gespeichert und gesucht werden können. Dem gegenüber stehen Daten welche die digitalen Objekte selbst mitbringen. In diesem Abschnitt werden nur erstere behandelt.

Um die Metadaten besser auf unterschiedlichen Datenspeichern ablegen zu können, wurde ein System von XML-Strukturen entwickelt, das es gestattet, neben den eigentlichen Daten wie Titel, Autor usw. auch Struktur- und Service-Informationen mit abzulegen. Die eigentlichen Nutzerdaten sind wiederum typisiert, was deren speicherunabhängige Aufzeichnung erheblich vereinfacht. Es

steht dem Entwickler einer Anwendung jedoch frei, hier bei Bedarf weitere hinzuzufügen. Im Folgenden soll nun der Aufbau der Metadatenobjekte im Detail beschrieben werden. Zum Verständnis des Samples sei hier auch auf den vorigen Abschnitt verwiesen. Die Metadaten werden komplett in XML erfasst und verarbeitet. Für die Grundstrukturen und Standardmetadatentypen werden seitens MyCoRe bereits XMLSchema-Dateien mitgeliefert.

### 4.2.2.1 XML-Syntax eines Metadatenobjektes

Abbildung 4: XML-Syntax eines Metadaten-Objektes

- Für **xsi:noNamespaceSchemaLocation** ist das entsprechende XMLSchema-File des Metadatentyps anzugeben (document.xsd)
- Die **ID** ist die eindeutige MCRObjectID.
- Der **label** ist ein kurzer Text-String, der bei administrativen Arbeiten an der Datenbasis das Identifizieren einzelner Datensätze erleichtern soll. Er kann maximal 256 Zeichen lang sein.
- Innerhalb der XML-Datenstruktur gibt es die Abschnitte **structure**, **metadata** und **service** zur Trennung von Struktur-, Beschreibungs- und Wartungsdaten. Diese Tag-Namen sind reserviert und **dürfen NICHT anderweitig verwendet werden!**

## 4.2.2.2 XML-Synatx des XML-Knotens structure

Im XML-Knoten **structure** sind alle Informationen über die Beziehung des Metadatenobjektes zu anderen Objekten abgelegt. Es werden derzeit die folgenden XML-Daten unter diesem Knoten abgelegt. Die Tag-Namen parents/parent, children/child und derobjects/derobject sind reserviert und

**dürfen NICHT anderweitig verwendet werden!** Alle Sub-Knoten haben einen Aufbau wie für MCRMetaLinkID beschieben.

In **parents** wird ein Link zu einem Elternobjekt gespeichert, sofern das referenzierende Objekt Eltern hat. Ob dies der Fall ist, bestimmt die Anwendung. Das Tag dient der Gestaltung von Vererbungsbäumen und kann durch den Anweder festgelegt werden. Siehe auch 'Programmers Guide', Abschnitt Vererbung. Die Werte für xlink:title und xlink:label werden beim Laden der Daten automatisch ergänzt.

Die Informationen über die **children** hingegen werden durch das MyCoRe-System beim Laden der Daten **automatisch** erzeugt und **dürfen nicht per Hand geändert werden**, da sonst das Gesamtsystem nicht mehr konsistent ist. Werden die Metadaten eines Kindes oder eines Baumes von Kindern gelöscht, so wird in diesem Teil des XML-Knotens der Eintrag durch die Software entfernt.

Dasselbe gilt auch für den XML-Unterknoten derobjects. In diesem Bereich werden alle Verweise auf die an das Metadatenobjekt angehängten digitalen Objekte gespeichert. Jeder Eintrag verweist mittels einer Referenz auf ein Datenobjekt vom Typ mycorederivate, wie es im nachfolgenden Abschnitt 'IFS und Content Store' näher erläutert ist.

**Abbildung 5:** XML-Syntax eines structure XML-Knotens

## 4.2.2.3 XML-Syntax des XML-Knotens metadata

Der Abschnitt **metadata** des MyCoRe-Metadatenobjektes nimmt alle Beschreibungsdaten des eigentlichen Datenmodells auf. Diese werden ihrerseits in vordefinierten Datentyp-Strukturen mit festgelegter Syntax abgelegt. Die Liste der Einzelelemente und die Reihenfolge der Typen ist dabei quasi beliebig in Anordnung und Länge. Wichtig ist nur, dass alle Datentypen bestimmte

gemeinsame Eigenschaften haben. Es ist auch jederzeit möglich, weitere Typen den Projekten der Anwender hinzuzufügen (siehe dazu das Dokument MyCoRe Programmer Guide).

Die Metadaten bestehen aus einer Ansammlung von Informationen rund um das multimediale Objekt. Vorrangig wird dieser Teil in der Suche abgefragt. Jedes Metadatum (auch Metadaten-Tag) enthält im class Attribut den Namen des MCRMeta-Typs bzw. der gleichnamigen MCRMeta-Java Klasse. Daneben gibt es noch ein Attribut heritable, in dem festgelegt wird, ob diese Metadaten vererbbar sein sollen. Weiterhin können noch die Attribute papasearch für die Einbindung in die parametrische Suche und textsearch für die Volltext-Suche über das gesamte Metadatenobjekt angegeben werden. Es sind jeweils die boolschen Werte true oder false möglich. Die mit der Vererbung verbundenen Mechanismen sind in dieser Dokumentation weiter hinten beschrieben.

Für MyCoRe wurden einige Basismetadatentypen festgelegt, mit denen die Mehrzahl der bisher in Betracht kommenden Anwendungen gelöst werden können. Die einzelnen Daten treten dabei als Liste auf, in denen mehrere Elemente des gleichen Typs erscheinen können, beispielsweise ein Titel in verschiedenen Sprachen. Jedes Listenelement hat wiederum per Default ein **type** Attribut und eine gemäß W3C spezifizierte Sprache im Attribut **xml:lang**. Die Angabe der Sprache im Tag metadata ist für alle eingschlossenen Metadatentypen der Default-Wert. Die Liste der aktuell unterstützten Sprach-Codes entnehmen Sie bitte der Java-Quelldatei

~/mycore/sources/org/mycore/common/MCRDefaults.java

Für interne Zwecke wurde ein weiteres Attribut inherited eingeführt. Dieses ist NICHT durch den Anwender zu verändern! Es wird gesetzt, wenn das betreffende Metadatum von einem Elternteil geerbt wurde (siehe Vererbung). Diese Information ist für die Datenpräsentation sehr hilfreich. Für das MyCoRe-Beispiel mit einem Dublin Core Datenmodell werden bereits einige Metadatentypen verwendet, welche dem MyCoRe-Kern beigefügt sind. Die Syntax der einzelnen

Abbildung 6: XML-Syntax eines metadata XML-Knotens

Typen wird in den nachfolgenden Absätzen genau beschrieben.

# 4.2.2.4 MyCoRe Metadaten-Basistypen

In MyCoRe gibt es eine Reihe von vordefinierten XML-Datenstrukturen zur Abbildung bestimmter mehr oder minder komplexer Daten. Diese Strukturen bilden die MyCoRe-Datentypen, welche von der Dateneingabe bis hin zur Validierung und Datenpräsentation für einen einheitlichen Umgang mit den Daten sorgen. Dabei ist zwischen einfachen, recht atomaren Typen und anwendungsspezifischen komplexen Typen zu unterscheiden. Eine Auflistung finden Sie in nachfolgender Tabelle.

einfache Typen	komplexe Typen
MCRMetaBoolean	MCRMetaAddress
MCRMetaClassification	MCRMetaCorporation

einfache Typen	komplexe Typen
MCRMetaDate	MCRMetaPerson
MCRMetsLangText	MCRMetaIFS
MCRMetaLink	
MCRMetaLinkID	
MCRMetaNumber	
MCRMetaXML	

**Tabelle 9:** MyCoRe-Datentypen

## 4.2.2.4.1 XML-Syntax des Metadaten-Basistyps MCRMetaAddress

Der Basistyp MCRMetaAddress beinhaltet eine Liste von postalischen Anschriften in der Ausprägung eines XML-Abschnittes. Dabei wird berücksichtigt, dass die Anschrift in verschiedenen Sprachen und in international gängigen Formen gespeichert werden soll. Die einzelnen Subtags sind dabei selbsterklärend. Die Angaben zu **type** und **xml:lang** sind optional, ebenso die unter subtag liegenden Tags, jedoch muss mindestens eines ausgefüllt sein. Alle Werte werden als Text betrachtet. Das optionale Attribut textsearch hat keinen Effekt bei diesem Typ.

Abbildung 7: XML-Syntax des Metadaten-Basistyps MCRMetaAddress

Abbildung 8: Beispiel des Metadaten-Basistyps MCRMetaAddress

```
<addresses class="MCRMetaAddress" heritable="false" parasearch="true">
    <address type="Work" xml:lang="de">
    <country>Deutschland</country>
    <state>Sachsen</state>
    <zipcode>04109</zipcode>
    <city>Leipzig</city>
    <street>Augustuspaltz</street>
    <number>10/11</number>
    </addresse>

...
    </addresse>
```

### 4.2.2.4.2 XML-Syntax des Metadaten-Basistyps MCRMetaBoolean

Der Basistyp MCRMetaBoolean beinhaltet eine Liste von Wahrheitswerten mit zugehörigen **type** Attributen. Das optionale Attribut **textsearch** hat keinen Effekt bei diesem Typ. Folgende Werte sind zulässig:

```
für true - 'true', 'yes', 'wahr' und 'ja'
für false - 'false', 'no', 'falsch' und 'nein'
```

```
<tag class="MCRMetaBoolean" heritable="..." parasearch="...">
```

Abbildung 9: XML-Syntax des Metadaten-Basistyps MCRMetaBoolean

```
<publishes class="MCRMetaBoolean" heritable="true" parasearch="true">
    <publish type="Ausgabe_1" xml:lang="de">ja</publish>
    <publish type="Ausgabe_2" xml:lang="de">nein</publish>
    ...
    </publishes>
```

Abbildung 10: Beispiel des Metadaten-Basistyps MCRMetaBoolean

## 4.2.2.4.3 XML-Syntax des Metadaten-Basistyps MCRMetaClassification

Der Basistyp MCRMetaClassification dient der Einbindung von Klassifikationen<sup>12</sup> und deren Kategorien in die Metadaten. Beide Identifizierer zusammen beschreiben einen Kategorieeintrag

vollständig. Dabei ist für die categid eine, ggf. mehrstufige, Kategorie-ID einzutragen. Die classid muss vom Typ MCRObjectID sein. Das optionale Attribut textsearch hat keinen Effekt bei diesem Typ.

```
<tag class="MCRMetaClassification" heritable="..." parasearch="...">
    <subtag classid="..." categid="..."/>
    ...
    </tag>
```

Abbildung 11: XML-Syntax des Metadaten-Basistyps MCRMetaClassification

Abbildung 12: Beispiel des Metadaten-Basistyps MCRMetaClassification

### 4.2.2.4.4 XML-Syntax des Metadatentyps MCRMetaCorporation

Der Basistyp MCRMetaCorporation beinhaltet eine Liste von Namen einer Firma oder Einrichtung. Dabei soll berücksichtigt werden, dass die Name in verschiedenen Sprachen und in international gängigen Formen gespeichert werden sollen. Über das Attribut type ist eine Differenzierung der verschiedenen Namen (Abteilungen, Institute, Kurznamen usw.) möglich. name beinhaltet den vollständigen Namen, nickname das Pseudonym, parent den Namen der übergeordneten Einrichtung und property den rechtlichen Stand, GmbH. Das optionale Attribut textsearch hat keinen Effekt bei diesem Typ.

```
<tag class="MCRMetaCorporation" heritable="..." parasearch="...">
    <subtag type="..." xml:lang="...">
        <name>...</name>
        <nickname>...</nickname>
        <parent>...</parent>
        <property>...</property>
        </subtab>
        ...
        </tag>
```

Abbildung 13: XML-Syntax des Metadaten-Basistyps MCRMetaCorporation

Abbildung 14: Beispiel des Metadaten-Basistyps MCRMetaCorporation

## 4.2.2.4.5 XML-Syntax des Metadaten-Basistyps MCRMetaDate

Der Basistyp MCRMetaDate beschreibt eine Liste von Datumsangaben welche zusätzlich mit einem type Attribut versehen werden können. Das Darstellungsformat muss der angegebenen Sprache oder der ISO 8601 Notation folgen. Innerhalb von MyCoRe weden dann alle Datumsangaben in das ISO 8601 Format umgewandelt. Das optionale Attribut textsearch hat keinen Effekt bei diesem Typ.

Abbildung 15: XML-Syntax des Metadaten-Basistyps MCRMetaDate

Abbildung 16: Beispiel des Metadaten-Basistyps MCRMetaDate

## 4.2.2.4.6 XML-Syntax des Metadatentyps MCRMetaLangText

Der Basistyp MCRMetaLangText dient der Speicherung einer Liste von Textabschnitten mit zugehöriger Sprachangabe. Das Attribut **textsearch** bewirkt, dass alle Text-Values in einen gemeinsamen Textindex des Metadatenobjektes abgelegt werden. Über das **form** Attribut kann noch spezifizier werden, in welcher Form der Text geschrieben ist.

Abbildung 17: XML-Syntax des Metadaten-Basistyps MCRMetaLangText

```
<titles class="MCRMetaLangText" heritable="true" parasearch="true" textsearch="true">
  <title type="maintitle" xml:lang="de" form="plain">
  Mein Leben als MyCoRe-Entwickler
  </title>
  ...
  </title>
```

Abbildung 18: Beispiel des Metadaten-Basistyps MCRMetaLangText

## 4.2.2.4.7 XML-Syntax der Metadatentypen MCRMetaLink und MCRMetaLinkID

Der Basistyp MCRMetaLink wurde geschaffen, um eine Verküpfung verschiedener MyCoRe-Objekte untereinander zu realisieren. Ausserden können hier genauso Verweise auf beliebige externe Referenzen abgelegt werden. Der Typ MCRMetaLink ist eine Implementation des W3C XLink Standards<sup>13</sup>. Auf dieser Basis enthält der MyCoRe-Metadatentyp zwei Arten von Links eine Referenz und einen bidirektionalen Link. Bei beiden werden jedoch in MCRMetaLink nicht alle Möglichkeiten der XLink Spezifikation ausgeschöpft, da dies für die in MyCoRe benötigten Funktionalitäten nicht erforderlich ist.

Im Referenztyp ist das Attribut **xlink:type='locator'** immer anzugeben. Die eigentliche Referenz wird im **xlink:href** Attribut notiert. Dabei kann die Referenz eine URL oder eine MCRObjectID sein. Daneben können noch weitere Informationen im **xlink:label** angegeben werden, die Rolle einer verlinkten Person. Der Referenztyp kommt im MyCoRe-Sample bei der Verlinkung von Dokumenten und Personen zum Einsatz. Um den Update-Aufwand in Grenzen zu halten, wurde die genannte Verbindung als Referenz konzipiert. Somit weiß das referenzierte Objekt im Sample nichts über den Verweis.

Alternativ dazu besteht die Möglichkeit eines bidirektionalen Links. Dieser wird sowohl in der Link-Quelle wie auch im Link-Ziel eingetragen. Der Typ ist in diesem Fall **xlink:type='arc'**.

Weiterhin sind die Attribute **xlink:from** und **xlink:to** erforderlich. Optional kann noch ein Titel in xlink:title mitgegeben werden. Das optionale Attribut textsearch hat keinen Effekt bei diesem Typ.

Der Basistyp MCRMetaLinkID entspricht im Aufbau dem MCRMetaLink. Der einzige Unterschied ist, dass die Attribute **xlink:href**, **xlink:from** und **xlink:to** nur mit MCRObjectID's belegt werden dürfen.

```
<tag class="MCRMetaLink" heritable="..." parasearch="...">
    <subtag xlink:type="locator" xlink:href="..." xlink:label="..."
    xlink:title="..."\>
    <subtag xlink:type="arc" xlink:from="..." xlink:to="..." xlink:title="..."\>
    ...
</tag>
```

Abbildung 19: XML-Syntax des Metadaten-Basistyps MCRMetaLink

```
<urls class="MCRMetaLink" heritable="false" parasearch="...">
    <url xlink:type="locator" xlink:href="http://www.zoje.de" xlink:label="ZOJE"
    xlink:title="Eine externe URL"\>
        <url xlink:type="arc" xlink:from="mcr_object_id_1"
    xlink:to="mcr_object_id_2" xlink:title="Link zwischen Objekten"\>
        ...
    </urls>
```

Abbildung 20: Beispiel des Metadaten-Basistyps MCRMetaLink

## 4.2.2.4.8 XML-Syntax des Metadatentyps MCRMetaNumber

Der Basistyp MCRMetaNumber ermöglicht das Speichern und Suchen von Zahlenwerten. Die Zahlendarstellung kann je nach Sprache, d. h. im Deutschen mit Komma und im Englischen mit Punkt, angegeben werden. Weiterhin sind die zusätzlichen Attribute **dimension** und **measurement** möglich. Beide Attribute sind optional, ebenso wie das Default-Attribut **type**. Das optionale Attribut textsearch hat keinen Effekt bei diesem Typ.

**Abbildung 21:** XML-Syntax des Metadaten-Basistyps MCRMetaNumber **Abbildung 22:** Beispiel des Metadaten-Basistyps MCRMetaNumber

### 4.2.2.4.9 XML-Syntax des Metadatentyps MCRMetaPerson

Der Basistyp MCRMetaPerson beinhaltet eine Liste von Namen für natürliche Personen. Dabei wird berücksichtigt, dass die Namen in verschiedenen Sprachen und international gängigen Formen auftreten können. Das Attribut **type** dient der Differenzierung der verschiedenen Namen einer Person, Geburtsname, Synonym, Kosename usw. **firstname** repräsentiert den/die Vornamen, **callname** den Rufnamen, **surname** den Familiennamen, **academic** den akademischen Titel und **peerage** den Adelstitel. Das optionale Attribut **textsearch** hat den Effekt, dass alle textlichen Werte des Namens in das allgemeine Feld zur Textsuche des Metadatenobjektes übernommen werden.

**Abbildung 23:** XML-Syntax des Metadaten-Basistyps MCRMetaPerson

Abbildung 24: Beispiel des Metadaten-Basistyps MCRMetaPerson

### 4.2.2.4.10 XML-Syntax des Metadatentyps MCRMetaXML

Der Basistyp MCRMetaXML wurde zusätzlich als Container für einen beliebigen XML-Baum in das Projekt integriert. Dieser wird in den Textknoten des Subtags gestellt und kann dort theoretisch beliebig groß sein. Achten Sie aber darauf, dass entsprechend vies Speicherplatz in dem XML-SQL-Store vorgesehen wird. Die Tag-Attribute **parasearch** und **textsearch** haben keine Wirkung.

Abbildung 25: XML-Syntax des Metadaten-Basistyps MCRMetaXML

Abbildung 26: Beispiel des Metadaten-Basistyps MCRMetaXML

#### 4.2.2.5 XML-Syntax des XML-Knotens service

Für die Einrichtung eines Workflow und um die Wartung großer Datenmengen zu vereinfachen, wurde der XML-Abschnitt service in das Metadatenobjekt integriert. Hier sind Informationen wie Datumsangaben und Flags für die Verarbeitung im Batch-Betrieb enthalten. Achtung, die Tag-Namen sind fest vorgegeben und dürfen nicht anderweitig verwendet werden!

Die Datumsangaben servdates verhalten sich analog zu denen in MCRMetaDate. Folgende Möglichkeiten für das Attribut type sind vorgesehen. Weitere Typen sind jedoch integrierbar.

- acceptdate Datum aus dem Dublin Core, kann frei verwendet werden.
- **createdate** Das Erzeugungsdatum des Objektes, dieser Wert wird **automatisch** beim Anlegen des Objektes erzeugt und **bleibt immer erhalten**!
- modifydate Das Datum des letzten Update, dieser Wert wird automatisch beim Update des Objektes erzeugt und bleibt immer erhalten!
- submitdate Datum aus dem Dublin Core, kann frei verwendet werden.
- validfromdate Datum aus dem Dublin Core, kann frei verwendet werden.
- validtodate Datum aus dem Dublin Core, kann frei verwendet werden.

Im servflags Teil können kurze Texte untergebracht werden. Die Anzahl der servflag Elemente ist **theoretisch** unbegrenzt.

Abbildung 27: XML-Syntax des service XML-Konotens

## 4.2.3 Das Speichermodell für die Multimediadaten (IFS)

Im bisherigen Verlauf dieses Kapitels wurden nur die beschreibenden Daten des multimedialen Objektes erläutert. Dieser Abschnitt beschäftigt sich damit, wie die eigentlichen Objekte dem Gesamtsystem hinzugefügt werden können. Im MyCoRe Projekt wurde zur Ablage der digitalen Objekte das Konzept des IFS entwickelt. Hier ist es möglich, über spezielle Konfigurationen festzulegen, in welchen Speicher (Store) die einzelnen Dateien gespeichert werden sollen.

Das Laden von Objekten erfolgt mittels einer Metadaten-Datei, welche alle Informationen über die zu speichernde(n) Datei(en) und ihre Beziehung(en) zu den Metadaten enthält. Die zu speichernden multimedialen Objekte werden im Weiteren als Derivate, also Abkömmlinge, bezeichnet, da ein Objekt in mehreren Formen, Grafikformaten, auftreten kann. Die Struktur der XML-Datei für Derivate ist fest vorgegeben, alle Felder, die nutzerseitig geändert werden können, sind unten beschrieben.

Abbildung 28: XML-Syntax des Derivate-Datenmodells

```
<?xml version="1.0" cncoding="ISO-8859-1" ?>
 <mycorederivate
 xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
 xsi:noNamespaceSchemaLocation="....xsd"
 xmlns:xlink="http://www.w3.org/1999/xlink"
 ID="..."
 label="..."
 <derivate>
  <linkmetas class="MCRMetaLinkID">
    <linkmeta xlink:type="locator" xlink:href="..." />
   </linkmetas>
   <internals class="MCRMetaIFS">
    <internal
     sourcepath="..."
    maindoc="..."
  </internals>
 </derivate>
 <service>
 </service>
</mycoreobject>
```

- Für **xsi:noNamespaceSchemaLocation** ist die entsprechende XMLSchema-Datei anzugeben (Derivate.xsd)
- Die **ID** ist die eindeutige MCRObjectID.
- Der **label** ist ein kurzer Text-String, der bei administrativen Arbeiten an der Datenbasis das Identifizieren einzelner Datensätze erleichtern soll. Er kann maximal 256 Zeichen lang sein.
- Die Referenz in **linkmeta** ist die MCRObjectID des Metadatensatzes, an den das/die Objekte angehängt werden sollen.
- Das Attribut sourcepath enthält die Pfadangabe zu einer Datei oder zu einem Verzeichnis, welches als Quelle dienen soll. Aus diesen Dateien kann nun eine Datei ausgewählt werden, welche den Einstiegspunkt bei HTML-Seiten darstellen soll. Bei einzelnen Bildern ist hier noch einmal der Dateiname anzugeben. Ist nichts angegeben, so wird versucht Dateien wie index.html usw. zu finden.

# 4.3 Anpassungen des MyCoRe-Samples

## 4.3.1 Grundlegendes

Um einen Dokument-Server oder andere MyCoRe-Anwendungen problemlos als eigenständige

Anwendung zu betreiben, ist es notwendig hierfür auch separate Speicherbereiche für die Daten und Objekte bereitzustellen. Hierzu muss die Konfiguration an verschiedenen Stellen geändert werden. Oft reicht schon die Änderung der Tabellennamen aus. Für diese Beispiel wird der Prefix **DOC** verwendet.

Im nachfolgenden Abschnitt wird davon ausgegangen, dass Sie den MyCoRe-Sample Baum in ein gesondertes Anwendungsverzeichnis kopiert haben, z. B. /docserv welches durch die Environment Variable z. B.

```
export DOCSERV_HOME=/docserv beschrieben wird.
```

An dieser Stelle sollen Sie auch noch einmal darauf hingewiesen werden, dass es auch unveränderliche Einstellungen gibt, welche Sie beim compilieren des MyCoRe-Kernes einmal festgelegt haben. Die betrifft vor allem die benutzte SQL-Datenbank (DB2, MySQL, ...) und den verwendeten Metadaten-Store (CM8, XML:DB,...). Diesen benutzen alle Ihre Applikationen gemeinsam!

Kopieren Sie nun wieder die private Konfigurationsdatei und bearbeiten Sie diese nach folgenden Gesichtspunkten:

```
cd ~/mycore-sample-application/config
cp mycore.properties.priv template mycore.properties.private
```

- Wenn Sie den Content Manager 8.2 einsetzen überprüfen Sie den Namen des Library-Servers und Tragen Sie das Zugangspasswort ein. Ändern Sie die Namen der ItemTypes für die Objekte und das IFS und deren Prefixe (zwei andere, noch nicht verwendete Zeichen). Weiterhin sollten Sie andere Index-Verzeichnisse für die Textsuche angeben. Siehe Konfiguration von IBM Content Manager 8.2.
- Weinn Sie mit eXist arbeiten wollen, ändern sie die Collection von mycore z. B. auf docserv. Diese Collection müssen Sie nun mittels eXist-Client analog zum MyCore-Sample anlegen. Siehe Die Nutzung von eXist als XML:DB Backend.
- Die Einstellungen für die JDBC-Treiber können Sie aus Ihrer beispiel-Konfiguration übernehmen, hier sind keine Anpassungen erforderlich, da Sie andere Tabellennamen verwenden.
- Nun folgt der wohl umfangreichste Bereich, in denen Sie Änderungen vornehmen sollten. Es ist sehr zu empfehlen, für jedes Projekt eigene Tabellen zu verwenden. Hierzu müssen z. B. in den Tabellennamen MCR durch eine beliebige andere Zeichenfolge ersetzt werden. Für den Dokumenten-Server bietet sich hier DOC an, also MCRXMLDER --> DOCXMLDER usw.
- Im Bereich des User Management sollten Sie die User- und Group-Namen sowie die angegebnen Passworte des Beispiels durch eigene Werte ersetzen.
- Der nächste Abschnitt gibt den Remote-Zugriff auf Ihr System an. Ändern Sie die Daten wie Host, Port und Servlet-Pathes auf die von Ihnen belegten Werte ab.
- Für die IFS-Stores in das lokale File-System und nach Lucene sind eigene Verzeichnisse anzugeben und auch anzulegen!
- Um mehr von den inneren Abläufen des MyCore-Projektes zu verstehen, kann es hilfreich sein, temporär den DEBUG-Mode im Logging-System einzuschalten.
- Auch die Durchsicht der anderen Konfigurationsdateien verbessert das Verständnis von MyCore.

## 4.3.2 Füllen des eigenen Dokumenten-Servers

Nachdem Sie alle Konfigurationen eingetragen und alle zugehörigen Verzeichnisse usw. erzeugt haben, können Sie auf Basis des Commandline-Tools nun erste Daten einlesen. Modifizieren Sie dazu ggf. die mitgelieferten Unix-Tools.

#### Klassifikationen

Erstellen Sie sich entsprechend der Hinweise unter Das Klassifikationen-Datenmodell eigene Klassifikationen und/oder modifizieren Sie die im MyCoRe-Projekt mitgelieferten.

## 4.4 Gestaltung der Web-Server

## 4.4.1 Nutzung von Tomcat und Apache2

#### 4.4.1.1 Allgemeines

Ziel dieses Szenarios ist, dass unter mcradmin (oder einem anderen User) mehrere Applikationen mit verschiedenen URL Aliasen parallel laufen und sich dabei nicht ins Gehege kommen. Konkret bedeutet dies, dass verschiedene Tomcat Instanzen, die über einen Connector in den Apache Server integriert sind, parallel nebeneinander laufen. Zudem können die einzelenen Applikationen über eigene URLs angesprochen werden was mit Apache über sogenannte virtual hosts realisiert wird. Das folgende Beispiel ist etwas SuSE spezifisch sollte sich jedoch ohne weiteres auch auf eine andere Distribution übertragen lassen . Eine sehr gute Anleitung findet sich jedoch auch in der Dokumentation von Tomcat.

#### 4.4.1.2 Installation von Tomcat

Es wurden folgende Versionen von Tomcat unter SuSE installiert:

- jakarta-tomcat-4.1.27-37
- apache2-jakarta-tomcat-connectors-4.1.27-37

Die Binaries können von der Tomcat-Hompage heruntergeladen werden.

#### 4.4.1.3 Arbeiten mit mehreren Tomcat-Instanzen

Für das Aktivieren mehrerer Tomcat-Instanzen sind folgende Environment-Varibalen notwendig,

**\$CATALINA\_BASE** und **\$CATALINA\_HOME**. Dabei verweist **\$CATALINA\_HOME** auf das installierte Tomat-Verzeichnis, also Bsp. /opt/jakarta/tomcat.

Die Varibale **\$CATALINA\_BASE** wird auf das Verzeichnis der zu installierenden Tomcat-Instanz gesetzt, Bsp. /work/mcradmin/papyri-tomcat . In dem angelegten Verzeichnis der Tomcat-Instanz

müssen dann noch folgende Verzeichnisse angelegt werden, work, conf, temp, webapps, logs und bin.

Das Verzeichnis *conf* wird von /*opt/jakarta/tomcat/conf* übernommen.

```
cp /opt/jakarta/tomcat/conf/* $CATALINA BASE/conf.
```

Im Verzeichnis **\$CATALINA\_BASE/conf** ist dann das File *server.xml* zu bearbeiten. Es müssen in dieser Datei die entsprechenden Ports eingetragen werden. Man sollte 5 aufeinanderfolgende Ports verwenden (Bsp. 8190-8194). Die Ports müssen in der */etc/services* noch nicht belegt sein. Im File *server.xml* sind folgende Zeilen anzupassen<sup>14</sup>:

<sup>14</sup>Rot markierter Text ist entsprechend anzupassen.

```
<Service name="DocServ-Instance">
    <!-- Define a Coyote/JK2 AJP 1.3 Connector on port 8019 -->
    <Connector
      className="org.apache.coyote.tomcat4.CoyoteConnector"
       port="8194" minProcessors="5" maxProcessors="75"
       enableLookups="false"
       acceptCount="10" debug="0" connectionTimeout="0"
       useURIValidationHack="false"
       protocolHandlerClassName="org.apache.jk.server.JkCoyoteHandler"/>
    <Engine name="Urzlib" defaultHost="urzlib.dl.uni-leipzig.de" debug="0"</pre>
jvmRoute="tomcat 02">
      <Logger className="org.apache.catalina.logger.FileLogger"</pre>
        prefix="apache log." suffix=".txt" timestamp="true"/>
      <Realm className="org.apache.catalina.realm.UserDatabaseRealm"</pre>
        debug="0" resourceName="UserDatabase"/>
      <!-- Access log processes all requests for this virtual host. -->
      <Valve className="org.apache.catalina.valves.AccessLogValve"</pre>
        directory="logs" prefix="urzlib access log."
        suffix=".txt" pattern="common" resolveHosts="false"/>
      <Host name="urzlib.dl.uni-leipzig.de" debug="10"</pre>
        appBase="/work/mcradmin/urzlib-tomcat/webapps"
        <!-- unpackWARs="false" autoDeploy="true" -->
        <Alias>urzlib</Alias>
        <Context path="/urzlib" docBase="ROOT" debug="10" />
        <Valve className="org.apache.catalina.valves.AccessLogValve"</pre>
          directory="logs" prefix="home access_log." suffix=".txt"
          pattern="common" resolveHosts="false"/>
        <Context path="/manager" debug="0" privileged="true"
          docBase="/opt/jakarta/tomcat/server/webapps/manager/" />
        <Context path="/admin" debug="0" privileged="true"</pre>
          docBase="/opt/jakarta/tomcat/server/webapps/admin/" />
      </Host>
    </Engine>
 </Service>
</Server>
```

Abbildung 29: Das Tomcat Konfigurationsfile server.xml

Unter \$CATALINA\_BASE/webapps ist noch ein Link zu setzen. Dieser zeigt auf das Verzeichnis, in welchem die Applikation liegt.

```
ln -s /home/mcradmin/mycore-sample-tomcat/webapps ROOT
```

Nach dem bearbeiten des Files server.xml ist das Startscript für diese Tomcat-Instanz unter \$CATALINA BASE/bin zu erstellen. Das Startscript, Bsp. urzlib.sh hat folgenden Inhalt<sup>15</sup>:

```
#!/bin/bash
# set the environment
CATALINA_BASE=/home/mcradmin/docserv-tomcat
export CATALINA_BASE
if [ $1 = 'start' ]
   then
   rm -r $CATALINA_BASE/logs/*
   fi
exec /opt/jakarta/tomcat/bin/catalina.sh "$@"
```

Abbildung 30: Das Listing des Start-Scriptes urzlib.sh

Nun kann diese Tomcat-Instanz gestartet werden.

### 4.4.1.4 Apache2 Installation

Wir haben unter SuSE den Apachen2 der Version apache2-2.0.48-9 installiert.

Es ist das File **workers2.properties** unter /etc/apache2 anzulegen, damit eine Verbindung vom Apachen zur Tomcat-Instanz hergestellt werden kann. Dieses File hat in unserem Beispiel folgenden Inhalt und ist entsprechend zu bearbeiten.

```
logger]
level=DEBUG

# Alternate file logger
[logger.file:0]
level=DEBUG
file=/var/log/jk2.log

[config:]
file=/etc/apache2/workers2.properties
debug=10
debugEnv=10

[uriMap:]
info=Maps the requests. Options: debug
debug=1
```

<sup>15</sup>Rot markierter Text ist entsprechend anzupassen.

```
[shm:]
info=Scoreboard. Required for reconfiguration and status with multiprocess
server
file=/var/log/jk2.shm
size=1000000
debug=1
disabled=1
[workerEnv:]
info=Global server options
timing=1
debug=1
logger=logger.file:0
[lb:lb]
#info=Default load balancer.
debug=1
[channel.socket:docserv.mydoamin.de:8194]
info=Ajp13 forwarding over socket
debug=0
tomcatId=docserv.mydomain.de:8194
disabled=1
keepalive=On
timeout=10
group=lb1
[channel.apr:docserv.mydomain.de:8194]
info=Ajp13 forwarding over socket
debug=0
tomcatId=docserv.mydomain.de:8194
disabled=0
keepalive=On
timeout=20
group=lb1
[status:status]
disabled=1
## Define mappings
[uri:docserv.mydomain.de/*.jsp]
#ver=0
disabled=2
#group=lb
group=ajp13:docserv.mydomain.de:8194
```

```
[uri:docserv.mydomain.de/servlets/*]
#ver=0
disabled=2
#group=1b
group=ajp13:docserv.mydomain.de:8194

[uri:/jkstatus/*]
#disabled=0
info=Display status information and checks the config file for changes.
group=status:status
```

Abbildung 31: Die Datei workers2.properties

#### 4.4.1.5 Einrichten virtueller Hosts

Das Einrichten virtueller Hosts erfolgt durch das Anlegen des Files *httpd.conf.local* unter dem Verzeichnis /etc/apache2.

In unserem Beispiel hat dieses File dann folgenden Inhalt<sup>16</sup>:

```
LoadModule jk2_module /usr/lib/apache2/mod_jk2.so

<IfModule mod_jk2.c>
    JkSet config:file /etc/apache2/workers2.properties

</IfModule>

<Directory "/*/WEB-INF/*">
    AllowOverride None
    Deny from all

</Directory>

NameVirtualHost 139.18.108.9:80
```

Abbildung 32: Die Datei http.local.conf

<sup>16</sup>Rot markierter Text ist wieder entsprechend Ihrer Anwendung anzupassen.

```
<VirtualHost docserv.mydomain.de:80>
#<VirtualHost 139.18.108.9>
#<VirtualHost *>
    ServerAdmin mcradmin@docserv.mydomain.de
    DocumentRoot /work/mcradmin/docserv-tomcat/webapps/ROOT
    ServerName docserv.mydomain.de
    ServerAlias docserv
    ErrorLog /var/log/apache2/docserv-errors
    TransferLog /var/log/apache2/docserv-access
    ServerPath /work/mcradmin/docserv-tomcat/webapps/ROOT
   Alias /urzlib "/work/mcradmin/docserv-tomcat/webapps/ROOT"
<Directory "/work/mcradmin/docserv/webapps/" >
  Options Indexes FollowSymLinks
  DirectoryIndex
  AddHandler jakarta-servlet2 .jsp
   Order deny, allow
  Deny from all
   Allow from all
</Directory>
</VirtualHost>
```

Dem Apachen muss nun noch mitgeteilt werden, dass es virtuelle Hosts gibt und das dieses File verarbeitet werden soll. Dies geschieht durch das Hinzufügen folgender Zeile in dem Konfigurationsfile /etc/sysconfig/apache2

```
# This allows you to add e.g. VirtualHost statements without
# touching
# /etc/httpd/httpd.conf itself, which makes upgrading easier.
#
APACHE_CONF_INCLUDE_FILES="/etc/apache2/httpd.conf.local"
```

Abbildung 33: Ein Ausschnitt aus der Datei /etc/sysconfig/apache2

Wenn nun alles richtig eingestellt ist, kann der Apache2 durch rcapache2 start aktiviert werden.

## 4.4.2 Arbeiten mit IBM Websphere

Im Kapitel 3 wurde bereits der Einsatz von IBM WebSphere in einer simplen Variante besprochen. Nun soll die Anwendung jedoch unter einer virtuellen Host-Adresse erreichbar sein. Dazu sind folgende Schritte erforderlich:

- Beschaffen Sie sich einen Alias für Ihren Host z. B. docserv.mydomain.de
- · Starten Sie den WebSphere-Admin-Client mit

/usr/WebSphere/AppServer/bin/startServer.sh server1

- Tragen Sie den Virtuell Host ein und vergeben Sie dem Eintag einen Namen z. B. dochost
  - Environment Virtual Hosts
  - New
  - Host docserv.mydomain.de mit Alias dochost eintargen
- Installieren Sie die Web-Anwendung in folgenden Schritten
  - ServerPath: .../docserv/docserv.war
  - ContextRoot: /
  - Next
  - · Default virtual Host: dochost
  - Next
  - Next
  - DocServApplication: dochost
  - Next
  - Verbindung mit Server herstellen dochost auswählen Apply
  - Next
  - Finish
- Nun muss noch ein Update von WebSphere erfolgen
  - Environment Update Web Server Plugin
  - OK
- Stoppen Sie den WebSphere-Admin-Client mit

/usr/WebSphere/AppServer/bin/stopServer.sh server1

• Starten Sie nun Ihre Anwendung mit

/usr/WebSphere/AppServer/bin/startServer.sh docserv

# 4.5 Ausbau des Dokumenten-Servers mit zusätzlichen MyCoRe-Komponenten

## 4.5.1 Anbindung anderer Dokumenten-Server an das System

MyCoRe bietet die Möglichkeit, mehrere Server-Instanzen mit gleichen Datenmodellen zu einem gemeinsamen virtuellen Server zusammenzuschalten. Dies ist relativ leicht zu konfigurieren. Wichtig ist dabei jedoch, dass die Datenmodelle in ihren Strukturen und Tag-Bezeichnern identisch sind, da sonst die Suche nach Dokumenten oder Objekten erfolglos verläuft.

Die Anzahl der zusammengeschalteten Server ist theoretisch nicht begrenzt, in der Praxis sind mehr als 5-10 bestimmt wenig sinnvoll. Das System ist so gestaltet, dass beim Ausfall einzelner Instanzen die Arbeit mit den anderen nicht beeinträchtigt wird. Es fehlen lediglich die Ergebnisse des ausgefallenen Servers. Bevor Sie mit der Konfiguration beginnen, sollten Sie den Abschnitt 'Die Zusammenarbeit mit anderen MyCoRe-Sample-Installationen' lesen.

Um weitere Systeme zu ergänzen oder deren Einträge zu änderen, gehen Sie wie folgend vor: Im Konfigurations-File *mycore.properties.private* unter \$DOCSERV\_HOME/config ist die Zeile mit **MCR.remoteaccess\_hostaliases** anzupassen und im File *mycore.properties.remote* ist der Zugriff auf die neue Instanz zu definieren.

```
# List of the remote server aliases
MCR.remoteaccess_hostaliases=remote,NewRemoteSystem

# Configuration for the new host with remote access
MCR.remoteaccess_NewRemoteSystem_query_class=org.mycore.backend.remote.MCRServ
letCommunication
MCR.remoteaccess_NewRemoteSystem_host=the.new.server.name
MCR.remoteaccess_NewRemoteSystem_protocol=http
MCR.remoteaccess_NewRemoteSystem_port=80
MCR.remoteaccess_NewRemoteSystem_query_servlet=/mycoresample/servlets/MCRQuery
Servlet
MCR.remoteaccess_NewRemoteSystem_ifs_servlet=/mycoresample/servlets/MCRFileNod
eServlet
```

Abbildung 34: Konfigurationseintrag für zusätzlich abzufragende Instanzen

Ergänzen Sie nun noch die Suchmasken unter \$DOCSERV\_HOME/config um die weiteren Search-Instanzen und Testen Sie Ihre Konfiguration. **Achtung, wenn Sie diesen Dienst anderen anbieten, muss Ihr Web-Server aktiv sein!** 

## 4.5.2 Einbindung weiterer Content Stores

## 4.5.3 Nutzung der OAI Schnittstelle

## 4.5.3.1 Grundlagen

Die Open Archives Initiative<sup>17</sup> hat 2001 ein offenes Protokoll für das Sammeln (Harvesting) von Metadaten vorgestellt. Dies geschah vor dem Hintergrund, dass gängige Suchmaschinen im WWW für die wissenschaftliche Nutzung wegen der i.d.R. unüberschaubaren Treffermenge und der fehlenden Qualität der angebotenen Treffer kaum nutzbar sind. Das **Open Archives Initiative Protocol for Metadata Harvesting (OAI-PMH)** liegt mittlerweile in der Version 2.0 vor.

Das OAI-PMH dient zur Kommunikation zwischen **Data Providern** und **Service Providern**. Unter einem Data Provider versteht man hierbei ein Archivierungssystem, dessen Metadaten von einem (oder mehreren) Service Provider(n) abgerufen werden, der diese als Basis zur Bildung von Mehrwertdiensten benutzt (z.B. der Suche über viele Archive gleichzeitig).

Zum besseren Verständnis der weiteren Dokumentation führe ich hier die wichtigsten Definitionen

<sup>17</sup>http://www.openarchives.org/

kurz an:

- Ein **Harvester** ist ein Client, der OAI-PMH Anfragen stellt. Ein Harvester wird von einem Service Provider betrieben, um Metadaten aus Repositories zu sammeln.
- Ein **Repository** ist ein über das Netzwerk zugänglicher Server, der OAI-PMH Anfragen verarbeiten kann, wie sie im Open Archives Initiative Protocol for Metadata Harvesting 2.0 vom 2002-06-14 beschrieben werden<sup>18</sup>. Ein Repository wird von einem Data Provider betrieben, um Harvestern den Zugriff auf Metadaten zu ermöglichen.

Der für MyCoRe und Miless implementierte OAI Data Provider ist zertifiziert und erfüllt den OAI-PMH 2.0 Standard.

#### 4.5.3.2 Der OAI Data Provider

MyCoRe bietet ein extrem flexibles Klassifikations-/Kategoriensystem. Der MyCoRe OAI Data Provider benutzt eine frei definierbare Teilmenge dieser Klassifikationen zur Strukturierung der Metadaten gemäß der Definition von Sets in OAI 2.0. An den Harvester werden also nur Metadaten ausgeliefert, die in diesen Klassifikationen erfasst sind, wobei die Klassifikationen eine Set-Struktur erzeugen. Zur weiteren Einschränkung kann eine zusätzliche Klassifikation (restriction classification) angegeben werden, in der die Elemente klassifiziert sein müssen, die für den OAI Data Provider aber nicht strukturbildend ist.

Sollen weitere Daten über OAI zugänglich gemacht werden, so bietet der OAI Data Provider die Möglichkeit, unter verschiedenen Namen mehrere Servlet-Instanzen zu betreiben, wobei eine Instanz jeweils ein OAI-Repository darstellt.

#### 4.5.3.3 Installation

Zur Einbindung des OAI Data Providers müssen Eintragungen in den Deployment Descriptor des Servletcontainers und in die mycore.properties erfolgen.

#### 4.5.3.4 Der Deployment Descriptor

Für jedes OAI-Repository muss eine Servlet-Instanz in den Deployment Descriptor nach folgendem Muster eingetragen werden:

Abbildung 35: Einbindung des OAI-Data-Providers in web.xml

<sup>18</sup>http://www.openarchives.org/OAI/openarchivesprotocol.html

```
<servlet id="OAIDataProvider">
   <servlet-name>
     OAIDataProvider
    </servlet-name>
    <servlet-class>
     org.mycore.services.oai.MCROAIDataProvider
    </servlet-class>
 </servlet>
 <servlet-mapping>
    <servlet-name>
     OAIDataProvider
   </servlet-name>
    <url-pattern>
      /servlets/OAIDataProvider
    </url-pattern>
 </servlet-mapping>
```

## 4.5.3.5 Die mycore.properties.oai

Bei den einzurichtenden Properties ist zwischen *instanzunabhängigen* und *instanzabhängigen* Properties zu unterscheiden. Instanzunabhängige Properties sind hierbei für jedes angebotene OAI-Repository gültig, instanzabhängige Properties beziehen sich auf das jeweilige OAI-Repository.

# 4.5.3.6 Instanzunabhängige Properties

- MCR.oai.adminemail=admin@uni-irgendwo.de (notwendig) Der Administrator der OAI-Repositories.
- MCR.oai.resumptiontoken.dir=/mycore/temp (notwendig) Ein Verzeichnis, in welches der OAI Data Provider Informationen über Resumption Token ablegt.
- MCR.oai.resumptiontoken.timeout=48 (notwendig) Die Zeit (in Stunden), für die die Informationen über die Resumption Token nicht gelöscht werden. Da das Löschen nur erfolgt, wenn auf ein OAI-Repository zugegriffen wird, können die Dateien evtl. auch länger aufgehoben werden.
- MCR.oai.maxreturns=50 (notwendig) Die maximale Länge von Ergebnislisten, die an einen Harvester zurückgegeben werden. Überschreitet eine Ergebnisliste diesen Wert, so wird ein Resumption Token angelegt.
- MCR.oai.queryservice=org.mycore.services.oai.MCROAIQueryService (notwendig) Die Klasse, die für das Archiv das Query-Interface implementiert. Für Miless ist dies oaiOAIService.
- MCR.oai.metadata.transformer.oai\_dc=MyCoReOAI-mycore2dc.xsl (notwendig) Das Stylesheet, das die Transformation aus dem im Archiv benutzten Metadatenschema in das für OAI benutzte OAI Dublin Core Metadatenschema durchführt. Wenn sich das im Archiv benutzte Metadatenschema ändert, muss dieses Stylesheet angepasst werden. Optional können weitere Stylesheets angegeben werden, die einen Harvester mit anderen Metadatenformaten versorgen, z.B. MCR.oai.metadata.transformer.rfc1806=MyCoReOAI-mycore2rfc.xsl. Diese Stylesheets benutzen als Eingabe das Ergebnis des ersten Stylesheets.

#### 4.5.3.7 Instanzabhängige Properties

Bei instanzabhängigen Properties wird der im Deployment Descriptor verwendete Servletname zur Unterscheidung für die einzelnen Repositories verwendet.

- MCR.oai.repositoryname.OAIDataProvider=Test-Repository (notwendig) Der Name des OAI-Repositories.
- MCR.oai.repositoryidentifier.OAIDataProvider=mycore.de (notwendig) Der Identifier des OAI-Repositories (wird vom Harvester abgefragt).
- MCR.oai.setscheme.OAIDataProvider=DocPortal\_class\_00000004 DocPortal\_class\_00000005 (notwendig) Die MyCoRe-Klassifikation, die zur Bildung der Struktur des OAI-Repositories verwendet wird.
- MCR.oai.restriction.classification.OAIDataProvider=DocPortal\_class\_00000006 (optional) Die MyCoRe-Klassifikation, die zur Beschränkung der Suche verwendet wird.
- MCR.oai.restriction.category.OAIDataProvider=dk01 **(optional)** Die MyCoRe-Kategorie, die zur Beschränkung der Suche verwendet wird.
- MCR.oai.friends.OAIDataProvider=miami.uni-muenster.de/servlets/OAIDataProvider (optional) Unter dieser Property können weitere (bekannte und zertifizierte) OAI-Repositories angegeben werden, um den Harvestern die Suche nach weiteren Datenquellen zu vereinfachen.

#### 4.5.3.8 Test

Um zu testen, ob das eigene OAI-Repository funktioniert, kann man sich des Tools bedienen, das von der *Open Archives Initiative* unter http://www.openarchives.org zur Verfügung gestellt wird. Unter dem Menüpunkt **Tools** wird der **OAI Repository Explorer** angeboten.

### 4.5.3.9 Zertifizierung und Registrierung

Ebenfalls auf der oben angegebenen Website findet sich unter dem Menüpunkt Community der Eintrag Register as a data provider. Dort kann man anfordern, das eigene Repository zu zertifizieren und zu registrieren. Die Antwort wird an die in den Properties eingetragene EMail-Adresse geschickt.

# 4.6 Die Verwendung der Kommandozeilenschnittstelle der Benutzerverwaltung

Mit Hilfe der Kommandozeilenschnittstelle können Sie administrative Aufgaben für ihre MyCoRe-Anwendung durchführen. So können Sie etwa Objekte (Dokumente, Derivate, Legal Entities, ...) oder Klassifikationen in das Repository einlesen, aktualisieren und löschen, Suchen durchführen und Objekte in Dateien exportieren. Diese Funktionalitäten sind insbesondere bei einer Migration eines bestehenden Systems zur Sicherung der Daten sehr sinnvoll.

Ein Teil der verfügbaren Kommandos der Kommandozeilenschnittstelle ermöglicht die Verwaltung von Benutzern, Gruppen und Privilegien. Diese Kommandos werden im folgenden vorgestellt. Oft werden bei den Kommandos XML-Dateien mit Definitionen von Benutzern, Gruppen und Privilegien erwartet. Die Syntaxen dieser XML-Beschreibungen finden Sie im ProgrammerGuide.

Es werden nicht alle Geschäftsprozesse der Benutzerverwaltung in den folgenden Kommandos abgebildet. Der Schwerpunkt liegt auf einem Management-Interface für administrativen Zugriff. Die GUI der Benutzerverwaltung (ab Version 1.0 verfügbar) wird die restlichen Geschäftsprozesse behandeln.

## 4.6.1 Allgemeine Kommandos

Die folgenden Kommandos sind allgemeiner Natur.

init superuser – Dieses Kommando wird nur bei der Installation und Konfiguration des MyCoRe-Systems verwendet. Dabei werden Daten über den zu verwendenen Administrationsaccount und den Gastaccount aus den Konfigurationsdateien gelesen, die grundlegenden Privilegien installiert und das Benutzersystem initialisiert.

check user data consistency – Dieses Kommando dient zur Kontrolle der Konsistenz des Benutzersystems. Alle Verbindungen zwischen Benutzern und Gruppen sowie zwischen Gruppen untereinander werden kontrolliert und Unregelmässigkeiten, die eventuell durch den Import von Daten (siehe weiter unten) entstenden sind, werden ausgegeben.

#### set user management to read only mode

set user management to read/write mode – Mit diesen Kommandos können die Daten der Benutzerverwaltung eingefroren werden. Dies sollte vor dem Exportieren von Daten in XML-Dateien geschehen, damit sich nicht wärend des Exports Daten ändern oder Objekte angelegt werden.

#### 4.6.2 Kommandos zum Arbeiten mit XML-Dateien

#### create user data from file {0}

create group data from file {0} – Diese Kommandos erwarten eine XML-Datei als Parameter. In dieser Datei müssen ein oder mehrere Definitionen von Benutzern oder Gruppen existieren, die dann in das System integriert werden. Ein Benutzerpasswort muss im Klartext in der definierenden XML-Datei vorliegen (für die Syntax siehe den ProgrammerGuide). Ist die Passwortverschlüsselung eingeschaltet (siehe mycore.properties.user), so wird das Passwort bei der Ablage in der Datenbank automatisch verschlüsselt. Bei der Erzeugung der Objekte wird die Korrektheit der Eingaben bezüglich vorhandener Regeln überprüft. So wird z.B. getestet, ob sich eine Gruppe durch schon vorhandene Gruppen im System implizit selbst enthält.

#### import user data from file {0}

import group data from file {0}- Diese Kommandos verhalten sich ähnlich den vorhergehenden Befehlen, mit dem Unterschied, dass Daten ohne Logiküberprüfung eingelesen werden und Benutzerpasswörter bei eingeschalteter Passwortverschlüsselung verschlüsselt in den XML-Dateien vorliegen müssen. Die Import-Befehle werden üblicherweise benutzt, wenn Objekte zuvor in XML-Dateien exportiert wurden und wieder eingelesen werden sollen.

#### update user data from file {0}

#### update group data from file {0}

update privileges data from file {0} – Mit diesen Befehlen werden bereits vorhandene Benutzer, Gruppen und Privilegien aktualisiert. Dabei ist zu bedenken, dass "update" im Sinne von "festsetzen auf neue Werte" zu verstehen ist, die Objekte also nach dem update genau die Definitionen haben, die in den XML-Dateien festgelegt werden. Einige der Attribute können allerdings nicht verändert werden, z.B. die Erzeuger-Accounts oder das Datum der Erzeugung. Müssen diese Daten unbedingt verändert werden, dann müssen die Objekte vorher gelöscht und neu angelegt werden.

save all users to file {0}
save all groups to file {0}
save all privileges to file {0}

save user {0} to file {1}

save group {0} to file {1} – Mit diesen Kommandos werden alle oder einzelne Objekte der Benutzerverwaltung in XML-Dateien gespeichert. Passwörter von Benutzern werden bei eingeschalteter Verschlüsselung verschlüsselt abgelegt.

encrypt passwords in user xml file {0} to file {1} - Passwortverschlüsselung kann durch einen Konfigurationsparameter in der Datei mycore.properties.user aktiviert oder deaktiviert werden. Dieses Kommando wird benötigt, wenn man ein bestehendes System mit nicht eingeschalteter Verschlüsselung auf ein System mit Verschlüsselung migrieren will. Dabei verfährt man folgendermaßen: Zunächst werden alle Benutzer des alten Systems mit dem Kommando (siehe oben) save all users to file in eine XML-Datei exportiert. Daraufhin wendet man encrypt passwords in user xml file {0} to file {1} auf diese Datei an und erhält damit verschlüsselte Passwörter in den XML-Dateien. Mit dem Kommando (siehe oben) update user data from file reintegriert werden. Daten in das System Danach Kommandozeilenschnittstelle geschlossen und die Verschlüsselung in mycore.properties.user eingeschaltet werden.

# 4.6.3 Kommandos zum direkten Arbeiten mit Objekten der Benutzerverwaltung delete user {0}

**delete group** {0} – Durch Angabe der ID von Benutzern oder Gruppen werden die Objekte mit diesen Kommandos aus dem System entfernt (und abhängige Objekte aktualisiert).

#### list all users

#### list all groups

**list all privileges-** Die Kommandos dienen dem Auflisten der Objekte der Benutzerverwaltung und sind selbsterklärend.

set password for user {0} to {1} – Mit Hilfedieses Befehls kann das Passwort eines Benutzers direkt über die Kommandozeile gesetzt werden. Voraussetzung ist, dass die notwendigen Privilegien vorliegen.

#### show user {0}

**show group {0}** – Mit diesen Kommandos werden ein Benutzer oder eine Gruppe, bestimmt durch Angabe der zugehörigen ID, in XML-Syntax dargestellt.Damit sind alle zugehörigen Daten einsehbar

#### enable user {0}

**disable user {0}** – Mit Hilfe dieser Kommandos können einzelne Benutzer temporär deaktiviert und wieder aktiviert werden. Ist ein Benutzer disabled, so kann er oder sie sich nicht mehr am System anmelden.

add group {0} as member to group {1}

remove group {0} as member from group {1}

add user {0} as member to group {1}

**remove user {0} as member from group {1}** – Mit diesen Kommandos kann direkt auf die Mitgliederlisten von Gruppen zugrgriffen werden, indem Mitglieder (sowohl Gruppen als auch Benutzer) hinzugefügt oder gelöscht werden können.

## 4.6.4 Das Sichern und Restaurieren der Benutzerverwaltungsdaten

Während der Initialisierung eines MyCoRe-Systems werden ein Administrationsaccount und ein Gastzugang eingerichtet zusammen mit den zugehörigen primären Gruppen (siehe Kommando *init superuser*). Dadurch ist das Sichern und Reimportieren der gesamten Daten der Benutzerverwaltung mit etwas mehr Handarbeit verbunden, weil der Administrationsaccount und Gastzugang zwar mit gesichert werden, aber vor einer Restauration der Daten z.B. nach einem Crash der SQL-Datenbank neu initialisiert werden müssen. Das bedeutet, dass sie bereits vorhanden sind und ein *import user data from file* deswegen nicht geht. Andererseits können sich die Daten dieser beiden Benutzer natürlich auch verändert haben, so dass die alten Daten wieder hergestellt werden müssen. Der folgende Ablauf führt zum Ziel. Dabei stehen <superuser> und <superuser-group> bzw. <guest> und <guest-group> für die in mycore.properties.private eingetragenen Parameter für den Administrations- und Gastzugang. In der MyCoRe-Kommandozeile werden die folgenden Befehle durchgeführt:

MyCoRe:> save user <superuser> to file <superuser.xml>

MyCoRe:> save user <guest> to file <guest.xml>

MyCoRe:> save group <superuser-group> to file <superuser-group.xml>

MyCoRe:> save group <guest-group> to file <guest-group.xml>

MyCoRe:> save all users to file <all-users.xml>

MyCoRe:> save all groups to file <all-groups.xml>

MyCoRe:> save all privileges to file <privileges.xml>

Die Benutzer <superuser> und <guest> sowie die zugehörigen Gruppen müssen aus den Dateien <all-users.xml> bzw. <all-groups.xml> manuell entfernt werden. Dann können alle Daten in einer neu erstellten SQL-Datenbank folgendermassen importiert werden:

MyCoRe:> init superuser

MyCoRe:> update privileges data from file <privileges.xml>

MyCoRe:> import user data from file <all-users.xml>

MyCoRe:> import group data from file <all-groups.xml>

MyCoRe:> update user data from file <superuser.xml>

MyCoRe:> update user data from file <guest.xml>

MyCoRe:> update group data from file <superuser-group.xml>

MyCoRe:> update group data from file <guest-group.xml>

MyCoRe:> check user data consistency

# 5. Hints & Tips / Troubleshooting

# 5.1 Eine zweite Instanz von eXist auf einem System einrichten

Wenn Sie eine zweite Instanz von eXist auf Ihrem System einrichten möchten, so ist es erforderlich, dass diese mit anderen Port-Nummern arbeitet. Andernfalls kommt es zum Konflikt und eXist lässt sich nicht starten.

#### Folgende Änderungen sind durchzuführen:

- Im Wurzel-Verzeichnis von eXist (\$EXIST\_HOME) ist in der Datei *client.properties* der Port von 8081 auf 8091 (oder einen anderen) zu ändern. Auch im Wert der **alternateURI** ist dies erforderlich.
- In *build.xml* ist ebendfalls der Port unter dem Wert **location** auf 8090 (oder einen passenden) zu ändern.
- Um die Änderungen vollständig zu machen, sollten Sie auch die Datei *backup.properies* entsprechend anpassen.
- Im Source-Code sind die Klassen org.exist.Server.java , org.exist.ServerShutdown.java, org/exist/exist.xsl , org.exist.InteractivClient.java und org.exist.client.InteractivClient.java anzupassen und mit build.sh neu zu compilieren.

Danach sollten Sie Ihre zweite eXist-Installation auf Ihrem System verwenden können. Hierfür sollten Sie einen zweiten Nutzer verwenden.